Mid

Artifical Intelligence

Farah Awad Al-zabin

Topic #1

* Artifical Intelligence:

التعريف الأول (1) is abranch of Computer Science that is related to the Automation of intelligaunt behavior.

هو فرع من الـ CS المرتبط بأتمتة السلوك الذكي

التعريف الثاني (2) Increasing the ability of computers to act Humanly think humanly, act relationally, think relationally.

* act humanly: Turing test

عن طريقه نعرف إذا البرنامج يتمتع بقدرات الذكاء الاصطناعي

إذا الآلة جاوبت بنفس طريقة الإنسان وتاخذ ردة فعل زي الإنسان هيك بنعتبرها ذكاء اصطناعي

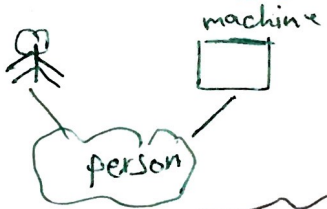

- اذا الشخص (Person) ما ميز انه البرنامج جاي من انسان او آلة معناها هذا البرنامج ← يتمتع بالذكاء الاصطناعي
- Turing Test ⇐ بعطيني Pass يا Fail

Pass: اذا ما قدر يميز بين اذا كان انسان أو آلة

Fail: اذا الشخص قدر يميز انه طلع من آلة أو انسان

* think humanly: Congnitive Science
* think relationally: Logic.
* act relationally: Unexpected Environment.

القدرة على التصرف بمنطقية بظروف غير متوقعة

Topic#2

* The Application of AI:

① Robotic vehicles (سيارة ذاتية القيادة (بدون سائق) (driverless cars)

↳ ex: 2005 STANLY

contain: Camera, sensors, Laser range Finders.

② Speech Recognition. التعرف على الأصوات

③ Game Playing.

↳ ex: Deep Blue

④ Spam Fighting: فرز الرسائل، الرسائل اللي مش مهمة بودّيها على spam

⑤ Robotics.

↳ ex: iRobot Corporation. شركة

↳ vacuum cleaners. مكنسة كهربائية تشتغل بنفسها

⑥ Machine Translation.

one word ⇒ Data base

statement ⇒ AI

ليست ذكاء اصطناعي

Topic #3

*The relation between AI and Search.

example [1] the N-puzzle Problem

N = 3 →

N = 8 →

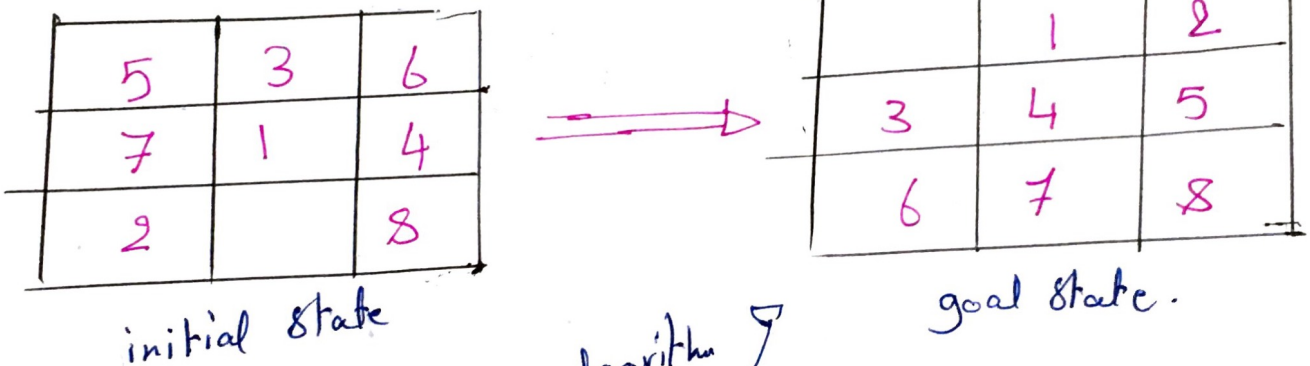

Example [2] The N-Queens problem

N = 4 ← 4 أعمدة 4 صفوف

N = 8 ← 8 صفوف 8 أعمدة

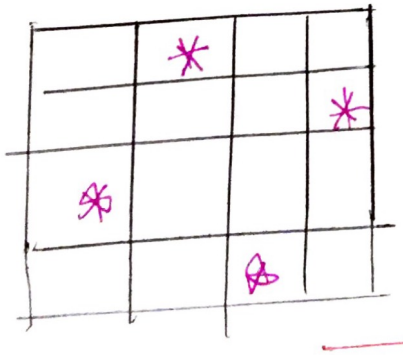

Incremental formulation

complete state formulation

- في النوع الأول ملكات حيث والأخرى تتقاطع الثانية
- عامودياً ولا أفقياً ولا على نفس القطر

Topic#4

- Measuring Problem-Solving performance.

المعايير اللي بتخلين اعمل comparing بين algorithms 2

1. Completeness.
2. optimality. => الحل الأفضل
3. time Complexity.
4. space Complexity.

غالباً space و time بعيد
بناءً على
space can's time complex.

Topic # 5

- Search Startegies:

Search
- Uniformed search (Blind)
  - distiguish goal from non-goal
- Informal Search (heuristic)
  - know wheather non-goal is more promising.

بس بدور عن الحل
بعشي فاعتبر اي اشارة
ادلني إذا قربت أو بعدت
عن الحل

هون بعتبر
اشارة إذا قربت
عن الحل أو بعدت

Topic #6

* Uniformal Search:

search of F

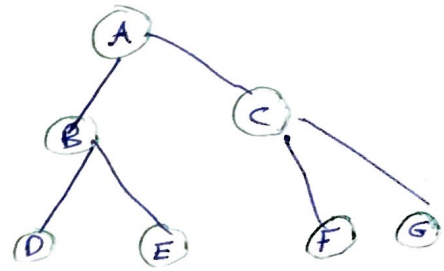

(1) Breadth first Search.

A B C D E F

(2) Depth first Search.

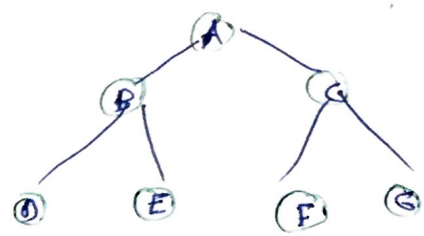

A B D E C F

(3) Uniform Cost Search.

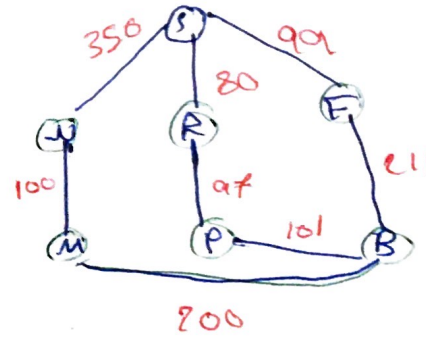

Source : S

Destination : B

path① S F B = 99 + 211 = 310

path② S R P B = 80 + 97 + 101 = 278 best path

path③ S N M B = 350 + 100 + 200 = 650

Answer = S R P B

Topic #7

* Heuristic Search algorithms.

Heuristic

Heuristic function — objective Function

(1) The 8-puzzle problem:

* h1 = the number of misplaced tiles — عدد الأرقام التي ليست في مكانها الصحيح بالنسبة للـ goal

h1 = 6

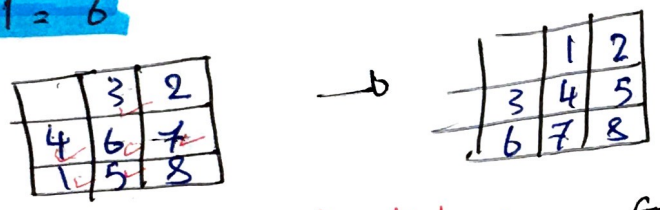

* h2 = the sum of distances — مجموع المسافات التي تحتاجها كل خطوة لكي تصل للـ Goal

h2 = 3+0+2+1+2+2+2+0 = 12

* h3 = the number of tiles that are in correctly place

h3 = 2

heuristic: يعرف مفهوم معين عن طريق الحدس أو البعد عن الكل

2 Evaluation Fundion (costs)

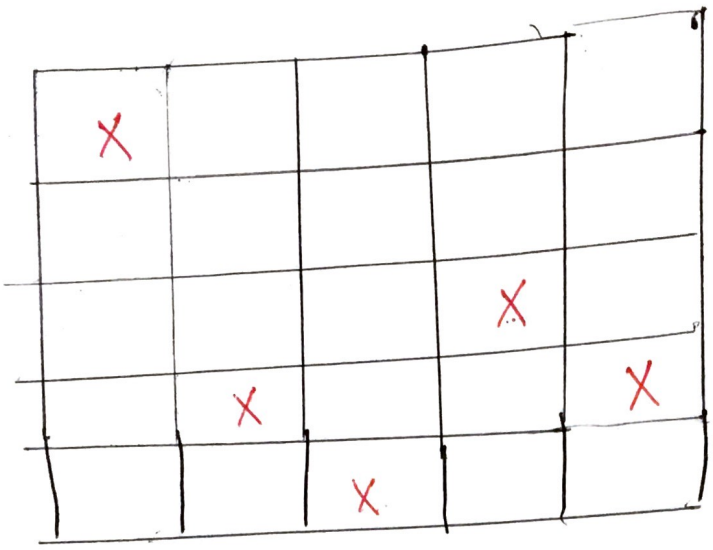

h2

بنروح على كل X الأولى وبنشوف كم عدد الـ Queens اللي مقاطعة طريقهم بين مكان الـ X الثانية وبنشوف كمان عدد الـ Queens اللي مقاطعة طريقهم وهيك ...

وبنفس الشي اذا بدي بنشوف الـ Queens اللي مقاطعة طريقي

h1(n): number of attacking queens (cost).

h2(n): number of non-attacking queens (objective).

- find h1(n) and h2(n) of the Drawn example.

h1 = 2+0+1+0+0 = 3

h2 = 2+3+1+1 = 7

* كلما كان h1 اذا كلما كان أفضل

* في حالة queen 4 ⇐ h2 = 3+2+1 = 6

اذا كان h2 = 6 معناها وهيك الحل

* في حالة queen 6 ⇐ 5+4+3+2+1 = 15

اذا كان h2 = 15 معناها لا هيك حل

rule

$$N\text{-queen} \Rightarrow \sum_{i=1}^{N-1} i$$

Topic #8

* Beyond Classical search.

① Brute - force.

- بتاخد كل الإحتمالات الممكنة مشكلتها وقت
- ميزتها انها accuracy (دقيقة)

heuristic search

- بتعطيني الإحتمالات الأقرب
- مشكلتها not accuracy

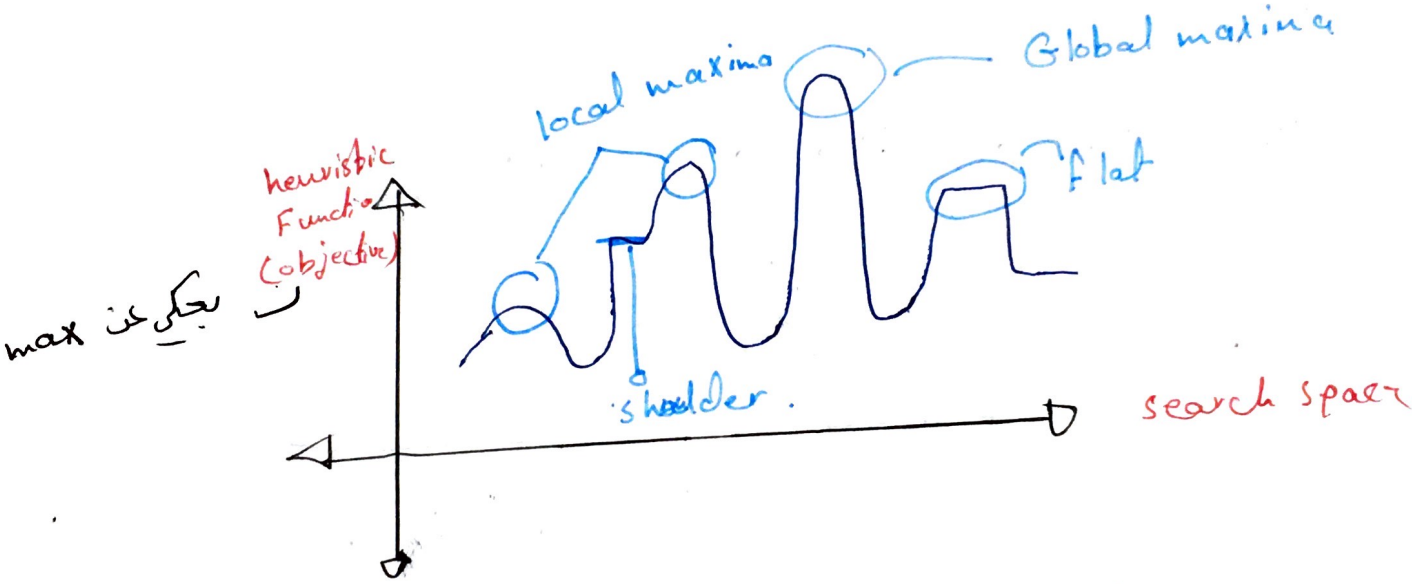

- لـ Flat بكون سطح بعدين نزول
- لـ shoulder بكون سطح بعدين طلع

* لو كان الجدال مش cost كان objective Min على نبدو

Topic #9

Hill Climbing algorithm

- hill climbing one of the optimization algorithms.

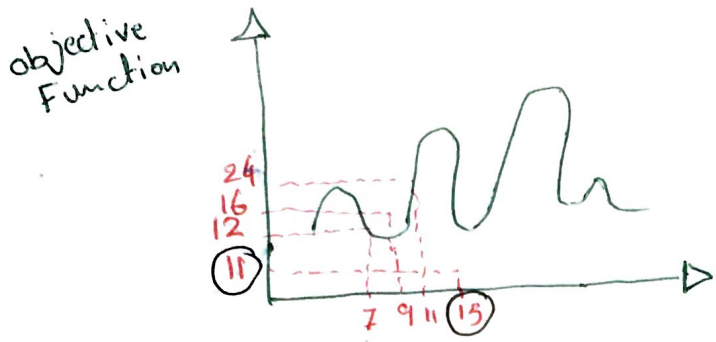

- ممكن يكون بيتم علاقة رياضية
$f(x)=2x+5$ مثلاً
- ممكن انه ما يكون علاقة رياضية

(heuristic)

* بال objective لما تصير القيمة أقل من السابقة بتوقف العقز
* بالمثال السابق لما صارت القيمة 11 وقلنا وقفنا هنا، والعقدنا الحل صحيح لأنه 24
* العقز بتم بشكل random اذا زادت القيمة معناها في تحسن واذا ما زادت معناها لا

* بال heuristic (cost) لما تصير القيمة اقل من السابقة بتوقف العقز
عكس الـ objective.

* get stuck in local maxima مشكلة موجودة في local maxima كبيرة.

* hill climbing required paramaters:
1. initial value بمعطيات او بتكون random
2. step size.

Algorithms
- traditional
- optimizat (randomes
احد اقسام عشوائية

Example(1) لازم انتبه اذا السؤال objective او cost

Given the following Cost Function

$f(x) = x^2 + 5$.

Apply the Hill Climbing algorithm to find best value.

assume $x_0 = -4$

step size = +2

كل مرة بشتغل +2 عشان بدي اوصل على القيمة الابتدائية

① بعوض -4 بالمعادلة .

$f(-4) = (-4)^2 + 5 = 21$

② بعدين بنقص 2 من -4 وبعوض -4-2=-2

$f(-2) = (-2)^2 + 5 = 9$ القيمة اقل نستمر بالحل

③ بما انه القيمة قلت نفضل كل ، -2+2=0

$f(0) = (0)^2 + 5 = 5$ القيمة اقل نستمر بالحل

④ بما انه القيمة زادت نتوقف ، 0+2=2

$f(2) = (2)^2 + 5 = 9$ القيمة زادت نتوقف حل X

the best value = 5 when x = 0

اقل قيمة من الحلول لانا بدنا cost

Global minimum

- اذا cost القيمة تصير اكبر من السابقة بتوقف حل .
- اذا objective اذا القيمة صارت اقل من السابقة فبتوقف حل

$x_0 = -3$ واذا كانت

step = +2

best = 6 when x = 1

اذا كانت stepsize كبيرة جدا بصير في مشكلة انه بصير يقفز عن كل الاحمر

Example 2: ماشي علاقة بالمثال

- suppose that the following 5-queens represent the initial state. Apply the hill climbing algorithm.

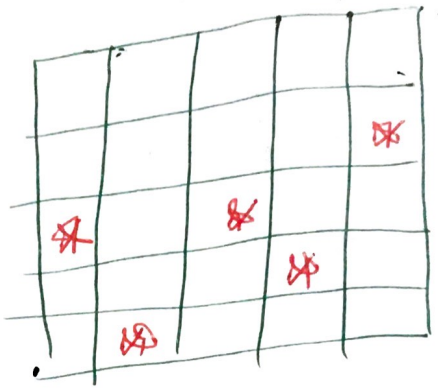

① we will suppose the number of attacking queens as our heuristic Function. (cost معناها بيم)

(أحل زي ما أخذنا بـ Topic 7 كيف نطلع h1 , h2)

initial state

$h(1) = 1+1+1+0+0 = 3$

(بشوف كم مرة تقاطع مع بعض)

② suppose that the software moves the queen in the first-left column to the top row.

(خلي أول ملكة حركة عشوائية وعتبار عشوائي (لا يعطى في السؤال) يجب العوم انها حركة عشوائية وضوية ، والنظر إذا كان هيالك تحسن أم لا (الهدف ان تقلل قيمة الـ cost)

$h(\text{next state}) = 1+2+1+0+0 = 4$

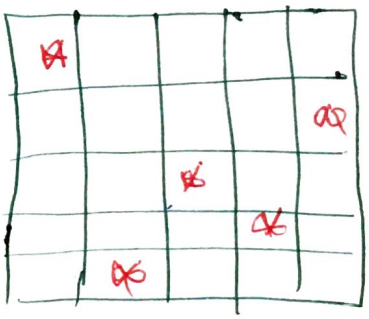

stop
لأنه القيمة زادت
واحنا بدنا cost تقل مو تزيد

initial state the best

---

* Random-restart algorithm

- حسن خوارزمية hill climbing .

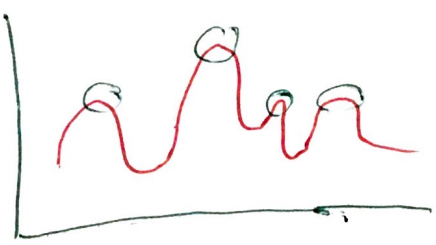

* بيرجع ويعطي قيم لإحادة البحث عن أعلى قيمة بطبيعة الـ hill climbing وعند إيجاد أعلى قيمة يخزنها ، وبعيد البحث عن قيمة أعلى ، والمبرمج يحدد عدد مرات الإحادة باستخدام for loop .

* ماشي هيفان انه يوصل للـ Global max لكن فرصة على الوصول على الـ Global max أعلى من hill climbing

* بياخد قيمة عشوائية فلما ياخد القيمة الأولى برجع بعيد عن أول وبعيد وهكذا ...

* Optimization Algorithm .

Exploration vs Exploiation

تصفح عام — الاهتمام بنقطة محددة

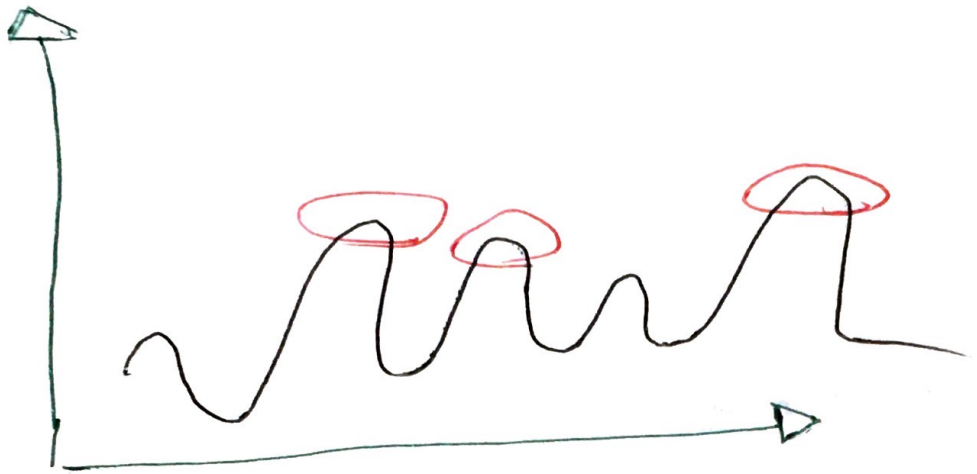

* التصفح يأخذ كل القيم ثم يحدد الأفضل .

* الأفضل البدء بالتصفح وبعدها الإهتمام بنقاط معينة ناجحة .

* أحد مساوئ Hill climbing أنها Expoliation أي أنها لا تنظر الى كل القيم والنقط .

Topic #10

• Genetic Algorithms.

- the N-queens problem could be presented. in two ways:

① 2D Arrays.

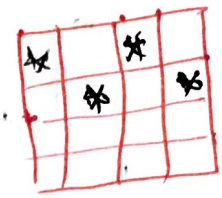

② String of ~~algorithm~~ alphonumeric (chromosomes)

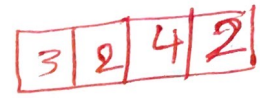

نقطة متقاطعة

* Steps Genetic Algorithms:

① Generate population.
② Evaluate fitnes.
③ Selection.
④ Gross Over
⑤ Mutation.

population	Fitnes	Probability	Selection	Cross Over	Mutation
2311	3	3/11 = 27% (total)	4231	4211	4231
4231	4	4/11 = 36%	2311	2331	1331
3234	1	1/11 = 9%	2311	2321	2321
3121	3	3/11 = 27%	3121	3123	2111
	11				

2 3 1 1

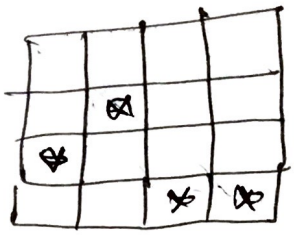

لعاهود الأول من اليسار والصف الثاني من تحت

h(2) = 1 + 2 + 0 = 3

عدد الكتل المتقاطعة + الغير متقاطعة

4 2 3 1

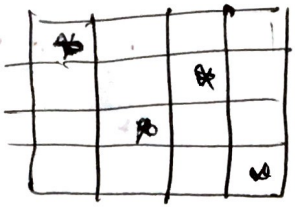

h(1) = 2 + 1 + 1 = 4

3 2 3 4

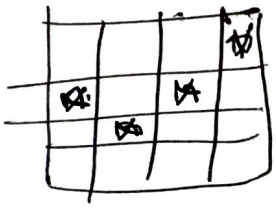

h(2) = 1 + 0 + 0 + 0 = 1

3 1 2 1

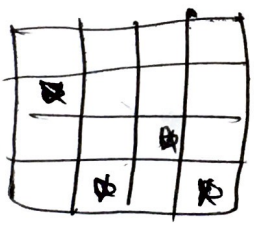

h(2) = 1 + 1 + 1 + 0 = 3

- probability كلما زادت تكون أفضل
- Cross over point في شرط أخذ من بعض
- Selection عشوائية حسب اللياقة

Topic # 11

* Learning (machine learning)

X	y
Age	Salary
22	225
45	450
31	312
55	550
39	400

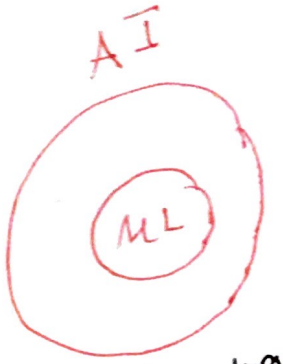

* machine learning part of AI
* الآلة جزء من الذكاء الاصطناعي AI

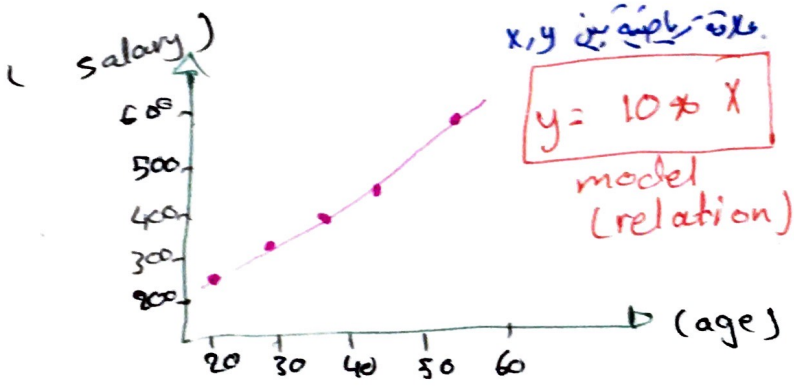

علاقة رياضية بين x,y

$y = 10 * X$

model (relation)

- هل من الممكن ان تكون العلاقة $y = 20 * X$ ؟ لا ، علاقة بعيدة جدا عن الواقع ، نسبة الخطأ كبيرة
* كلما كان نسبة الخطأ اقل أقرب للواقع يكون الحل أفضل

* هدف ML : ايجاد علاقة (خوارزمية) . و التنبؤ .
* ML ← مجموعة بيانات (مدخلات + مخرجات) إذا اقدرت اطلع معادلة رياضية تربط الـ input بالـ output نسميها Learning .

Learning

Supervised — بيانات معها output

Unsupervised — بيانات بدون output (clustering)

semi-supervised — مجموعة بيانات جزء منها عنده labels وجزء فيها Not labels. يعني جزء بطلعله output وجزء لا

Classification — مجموعة بيانات الـ output اجابات محددة مثلاً Yes or No

مثال المستشفى

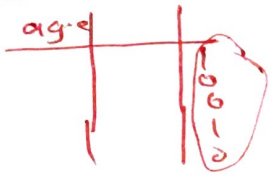

discrete value

Regression — مثل: مكتب عقارات

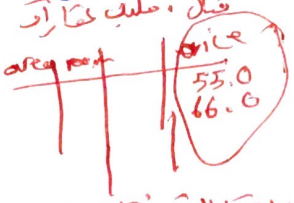

= احتمالات مختلفة (مفتوحة).

continuous-Range

- اذا في ارقام مختلفة بالـ output نحكي انها Regression
- clustering ⇐ معلومات بدون output
- الـ output في M.L تنقسم الى Labels (supervised)
- الخوارزمية بدنا اياها عشان تعمل model واذا قدر شتقة المعادلة مثلها الخوارزمية جابتلنا model
- المهم انه نقدر نتنبأ بالـ output الجديد بناءً على البيانات الموجودة

Topic 12

* Training data Vs Testing data.

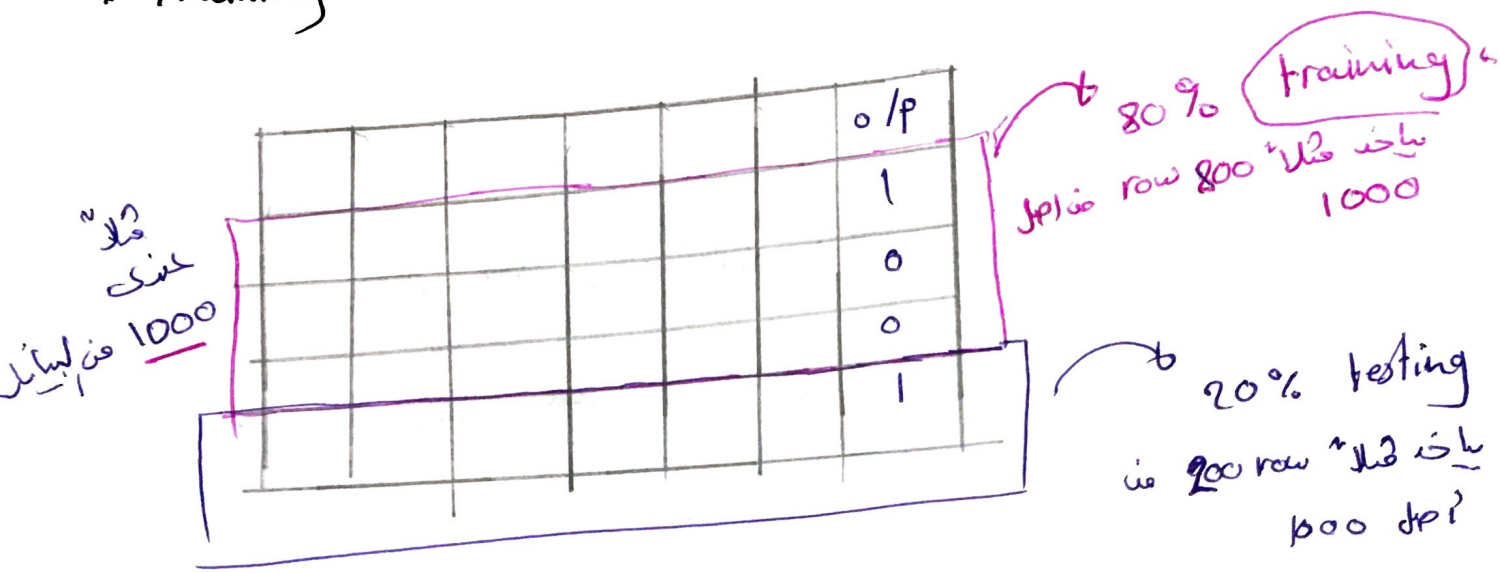

* training: بجمع البيانات اللي فيها input و output.

* testing: بجمع البيانات بس بعطيه الـ input بس والجواب اللي بطلع قارنه مع الـ output عشان أشوف هل هو صح ولا غلط.

* الهدف من الموديل هو التنبؤ.

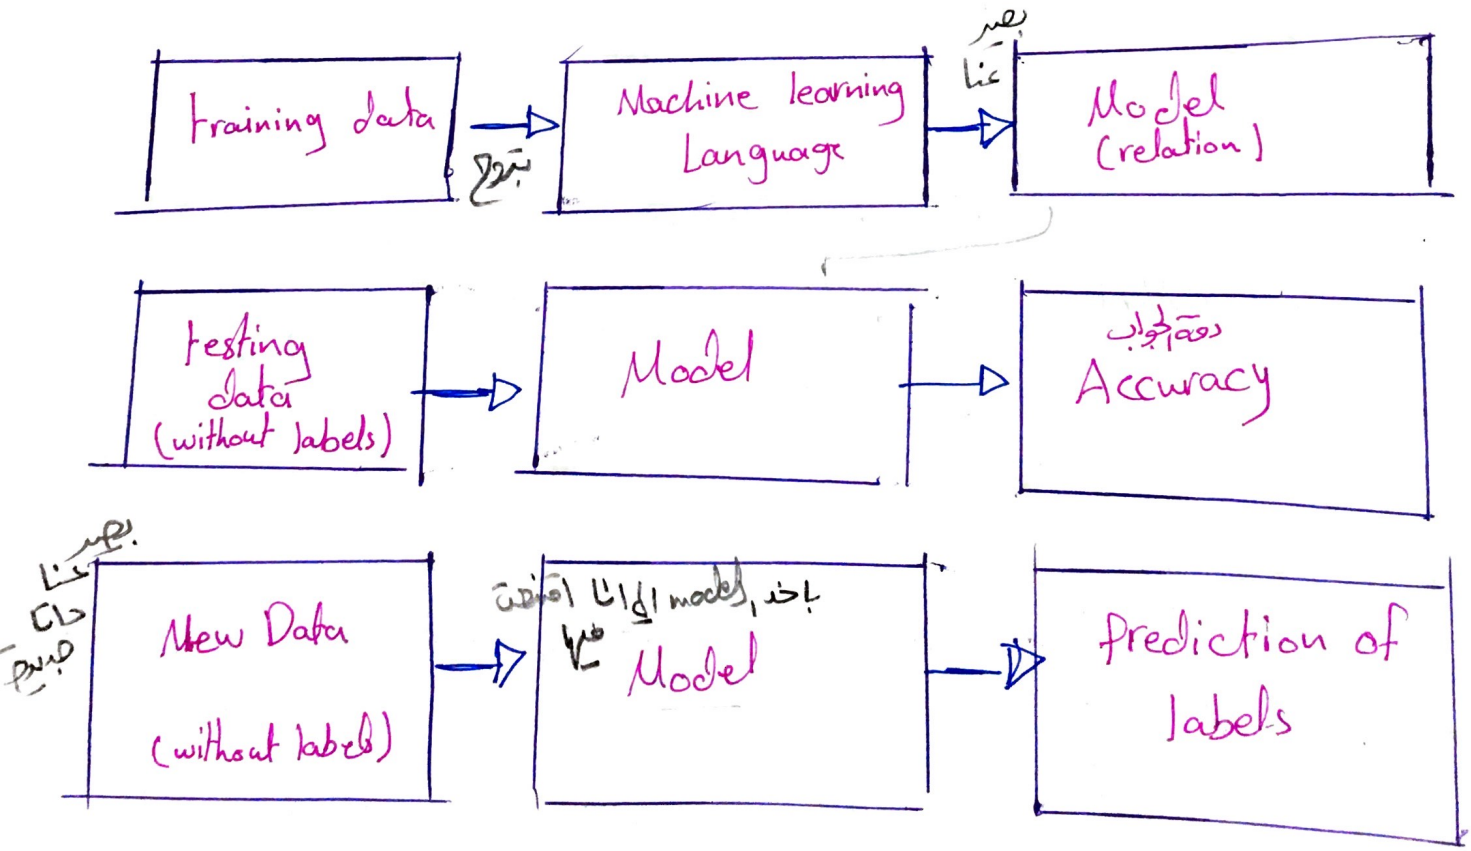

Topic #13

* Accuracy of Model.

* Accuracy of Classification model =

$$= \frac{\text{Number of correct Cases (in testing data)}}{\text{total Number of Cases (in testing data.}}$$

or.

* example:

	o/p	algo	
1	1	0	X
2	0	0	✓ ①
3	0	0	✓ ②
4	1	0	X
5	1	1	✓ ③
6	0	0	✓ ④

العمود للتوقعة من قبل Algorithm.

$\frac{4}{6} * 100$

---

* Accuracy of regression is calculated using RMSE:

error كلما كانت القيمة أقل وأقرب للصفر أحسن

$$RMSE = \frac{\sqrt{\sum_{i=1}^{n} (real - predicted)^2}}{n}$$

* إذا ما حطيت التربيع السالب يلغي الموجب وما نتبسفيه

example: 200 عدد الـ rows

o/p	algo
20.5	24.1
31.3	30.7
112.3	112.4

$$RMSE = \frac{\sqrt{(20.5-24.1)^2 + (31.3-30.7) + (112.3-112.4) + \dots}}{\text{عدد الحالات بال Test cases 200}}$$

* إلين قدرش أنا هيبة عن القيمة الحقيقية

Topic #14

* (k)- Means algorithm:

- used in clustering

Example:

P_1	P_2	P_3	P_4	P_5	P_6	P_7
2	8	7	9	1	3	10

Apply the k-means algorithm to make two groups of those number.

$C_1 = 6$ $\quad$ $C_2 = 9$ (g_2)

random value.

group 1

C_1 , P_1 الفرق بين

$d(P_1, C_1) = 4$ $\quad$ $d(P_1, C_2) = 7$ $\quad$ $P_1 \in g_1$

$d(P_2, C_1) = 2$ $\quad$ $d(P_2, C_2) = 1$ $\quad$ $P_2 \in g_2$

$d(P_3, C_1) = 1$ $\quad$ $d(P_3, C_2) = 2$ $\quad$ $P_3 \in g_1$

$d(P_4, C_1) = 3$ $\quad$ $d(P_4, C_2) = 0$ $\quad$ $P_4 \in g_2$

$d(P_5, C_1) = 5$ $\quad$ $d(P_5, C_2) = 8$ $\quad$ $P_5 \in g_1$

$d(P_6, C_1) = 3$ $\quad$ $d(P_6, C_2) = 6$ $\quad$ $P_6 \in g_1$

$d(P_7, C_1) = 4$ $\quad$ $d(P_7, C_2) = 1$ $\quad$ $P_7 \in 2$

P_1 P_2 P_5 P_6

2 7 1 3 g_1

P_2 P_4 P_7

8, 9 10 g_2

$$C_1 = \frac{2+7+1+3}{4}$$

$$= \frac{13}{14}$$

$$= 3.33$$

$$C_2 = \frac{8+9+10}{3}$$

$$= \frac{27}{3}$$

$$= 9$$

$C_1 = 3.33$ $C_2 = 9$ قيم جديدة بزجج نكرر العملية بس بالجروبات الجديدة

$d(P_1, C_1) = 1.33$
$d(P_2, C_1) = 5.33$
$d(P_3, C_1) = 4.33$
$d(P_4, C_1) = 6.33$
$d(P_5, C_1) = 2.33$
$d(P_6, C_1) = 0.33$
$d(P_7, C_1) = 7.33$

$d(P_1, C_2) = 7$
$d(P_2, C_2) = 1$
$d(P_3, C_2) = 2$
$d(P_4, C_2) = 0$
$d(P_5, C_2) = 8$
$d(P_6, C_2) = 6$
$d(P_7, C_2) = 1$

$P_1 \in g_1$
$P_2 \in g_2$
$P_3 \in g_2$
$P_4 \in g_2$
$P_5 \in g_1$
$P_6 \in g_1$
$P_7 \in g_2$

(2 3 1) g_1 (8 7 9 10) g_2

$C_1 = \frac{2+3+1}{3}$

$C_1 = 2$

$C_2 = \frac{8+7+9+10}{4}$

$= 8.5$

* بنضل نعيد العملية إذا طلع زي بعض والأرقام رجعت لنفس الكلاس

$g_1 = (2, 7, 1, 3)$
$g_2 = (8, 9, 10)$

وهي هي نكون وصلنا للحل . إذا رجع

Topic # 15

* Functional - Approximation.
  - predictive Modeling.

Function

constant	Quadratic	linear Function
$y=5$	$y = x^2+5x+5$	$y = 3x+5$
$y=c$	$y=ax^2+bx+c$	$y=ax+b$

- Example # 1

Given following table, Apply the hill Climbing algorithm to Approximate the relation between x and y.

x	y
2	9
3	19
4	33

Hint: suppose the relation is Quadratic

Initial configuration:

$a_0 = 1$ move $a = +1$

$b_0 = -2$ move $b = +1$

$c_0 = 3$ move $c = -1$

Sol

step 1 $f_0(x) = a_0x^2 + b_0x + c$ → $f_0(2) = (2)^2 - 2(2)+3 = 3$

$f_0(x) = x^2 - 2x + 3$ → $f_0(3) = (3)^2 - 2(3)+3 = 6$

$f_0(4) = (4)^2 - 2(4)+3 = 11$

$$RMSE = \sqrt{\frac{(9-3)^2+(19-6)^2+(33-11)^2}{3}} = 14.66$$

step2 :

since

$f_1(x) = 2x^2 - x + 2$

$f_1(2) = 2*(2)^2 - 2 + 2 = 8$

$f_1(3) = 2*(3)^2 - 3 + 2 = 17$

$f_1(4) = 2*(4)^2 - 4 + 2 = 30$

$RMSE_1 = \sqrt{\frac{(9-8)^2 + (19-17)^2 + (33-30)^2}{3}}$

$= \frac{6}{3} = 2$

since $RMSE_1 < RMSE_0$ we will continue.

step3

$f_2(x) = 3x^2 + 1$

$f_2(2) = 3*2^2 + 1 = 13$

$f_2(3) = 3*3^2 + 1 = 28$

$f_2(4) = 3(4)^2 + 1 = 49$

$RMSE_2 = \sqrt{\frac{(9-13)^2 + (19-28)^2 + (33-49)^2}{3}}$

$= 9.67$

since $RMSE_2 > RMSE_1$

we will stop

the result : $f(x) = 2x^2 - x + 2$

Example2 : Apply the GA to Approximate the relation in Ex1 :

GA باستخدام الخوارزمية Genetic Approximation

sol

				fitness (RMSE)	probability	cross over
$7x^2 - 2x + 5$	7	-2	5	12.3		
$2x^2 + 2x + 3$	2	1	3			
$5x^2 + 2$	5	0	2			
$2x^2 + x + 1$	2	1	1			
$17x^2 + x - 3$	17	1	-3			
$8x^2 - 2x$	8	-2	0			

RMSE الأقرب إلى الصفر هو الأفضل بين الـ 6 fitness ، وهو 22.

Topic# 16

- Game Theory:

A branch of mathematics used to made the interact between different flayers in content with predefined rules and outcomes

— يكون في تفاعل بين اللاعبين (منافسة)

⊙ Adverserial Search:

- MinMax algorithm

example:

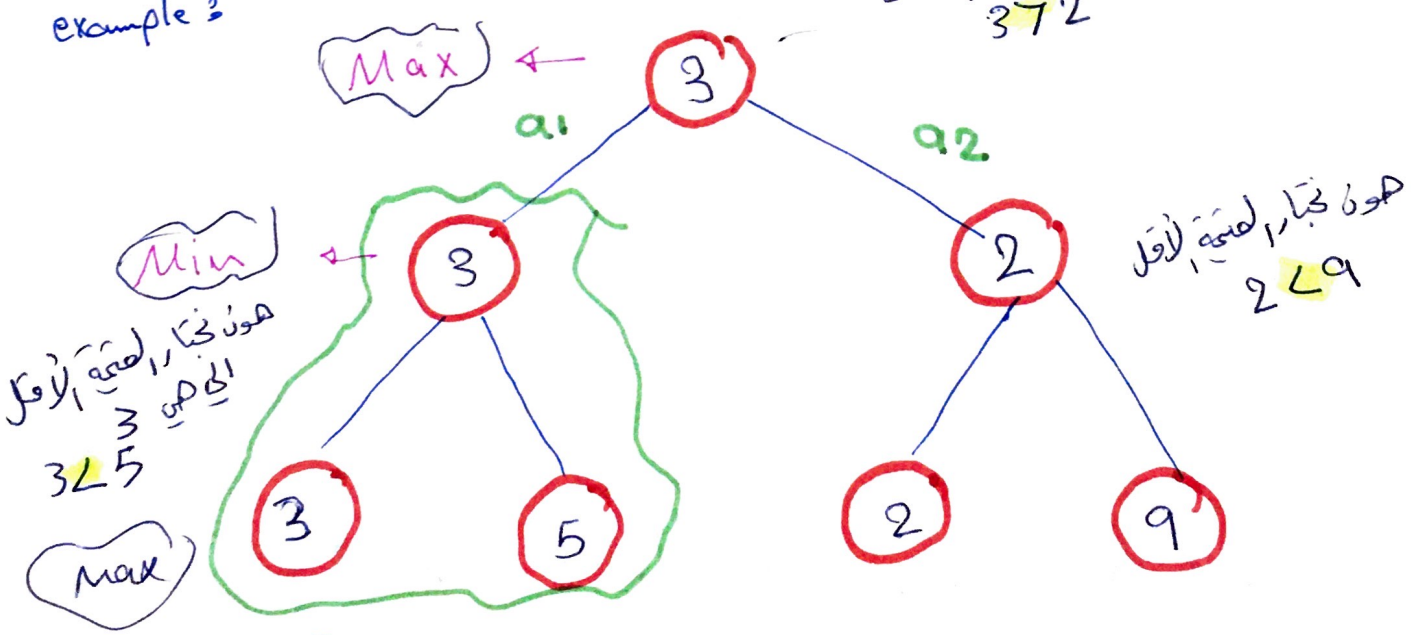

اختار الاعلى
3 ? 2

هون اختار الصغير الاقل
2 < 9

هون اختار الصغير الاقل
3 الي فيي
3 < 5

a1 ? 9

- الطريق الي لعبش فيه وكتاره بعد فا احد هو
- بكون معطيني اوسعة والارقام الي كدة وبطلب في اي طريق احدد
- Back tracking بلش من كدة بعد اول اشي بشوف الMin د ٣ و ٥
بعدين بشوف الmin د ٢ و ٩ بعدين بطلع فوق وبطلع الMax
د ٢ و ٣

Example 2:

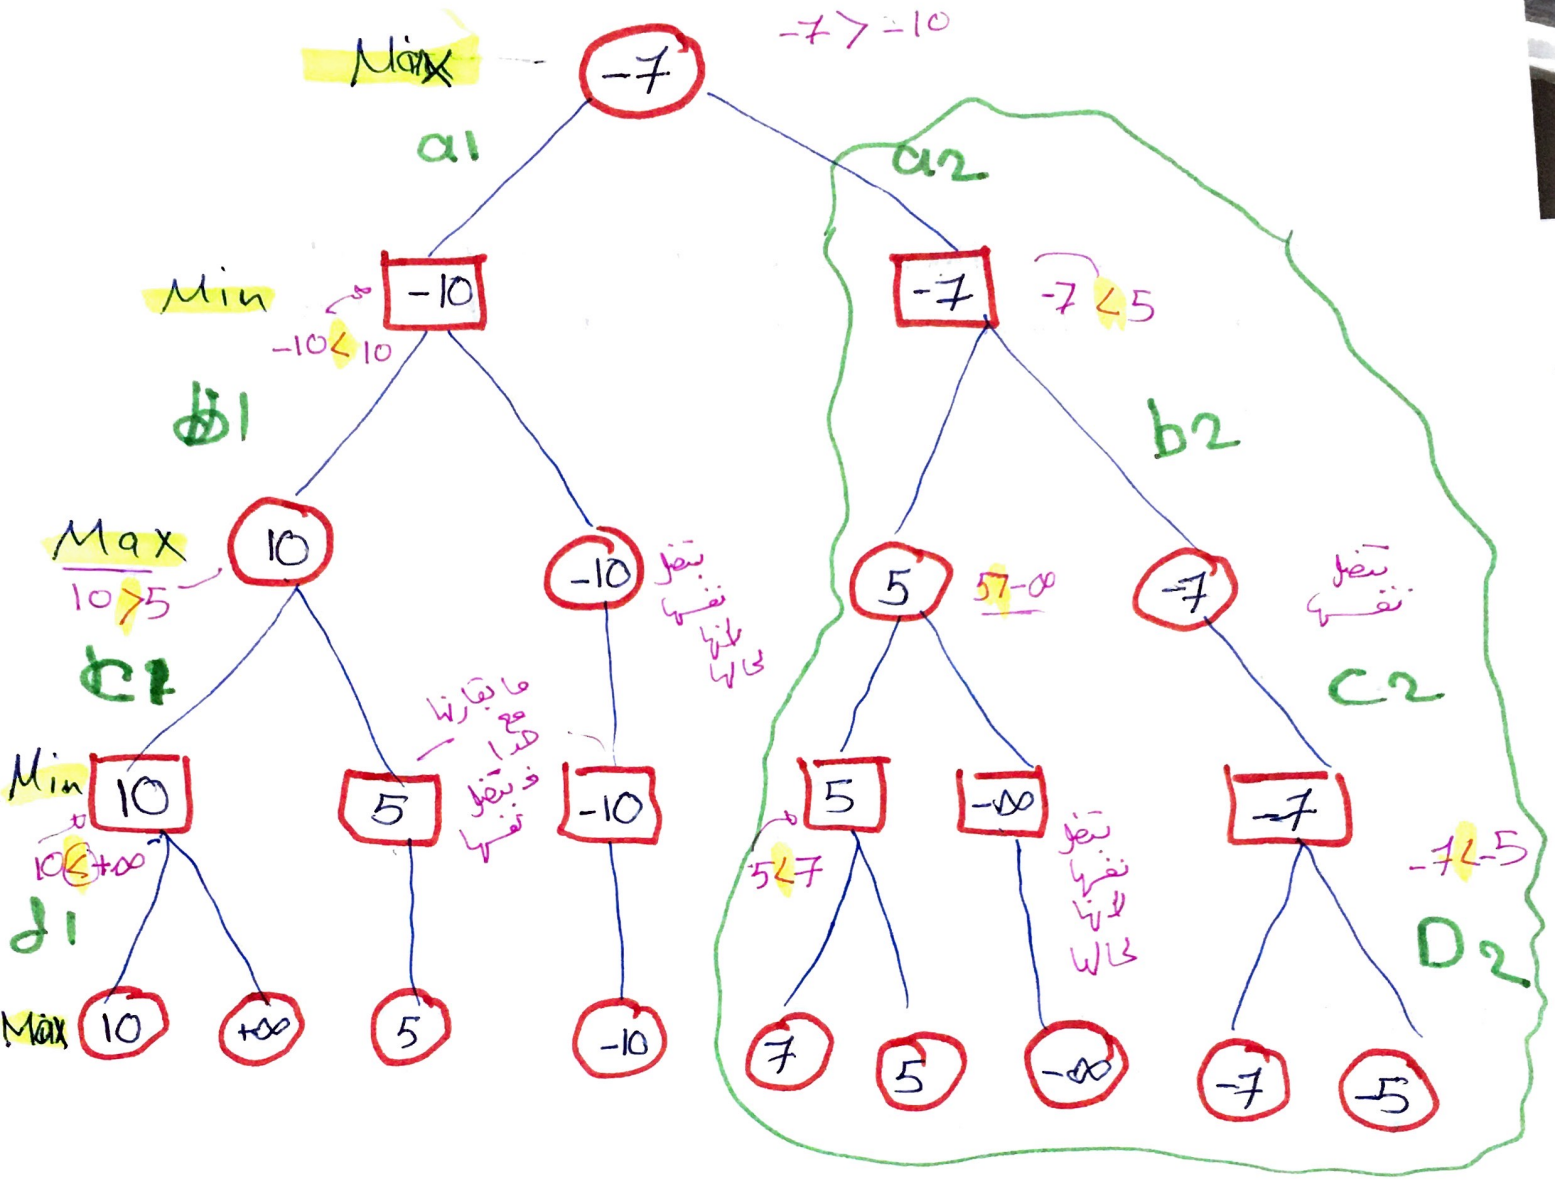

* دايماً باكل نفسي Max فبي أول خطوة نبط أماكن الـ Max والـ Min بعدين نقارن بناءً عليهم.

Max
Min
Max
Min

* هو بكون معطينا اي تخت او عكس بحيلنا نعبي الفراغات اي ناقصة
* بيلش من تحت زي ما هو موضح بالرسمة
* الطريق اي بتبعة (a2 b2 c2 D2)

Example 3

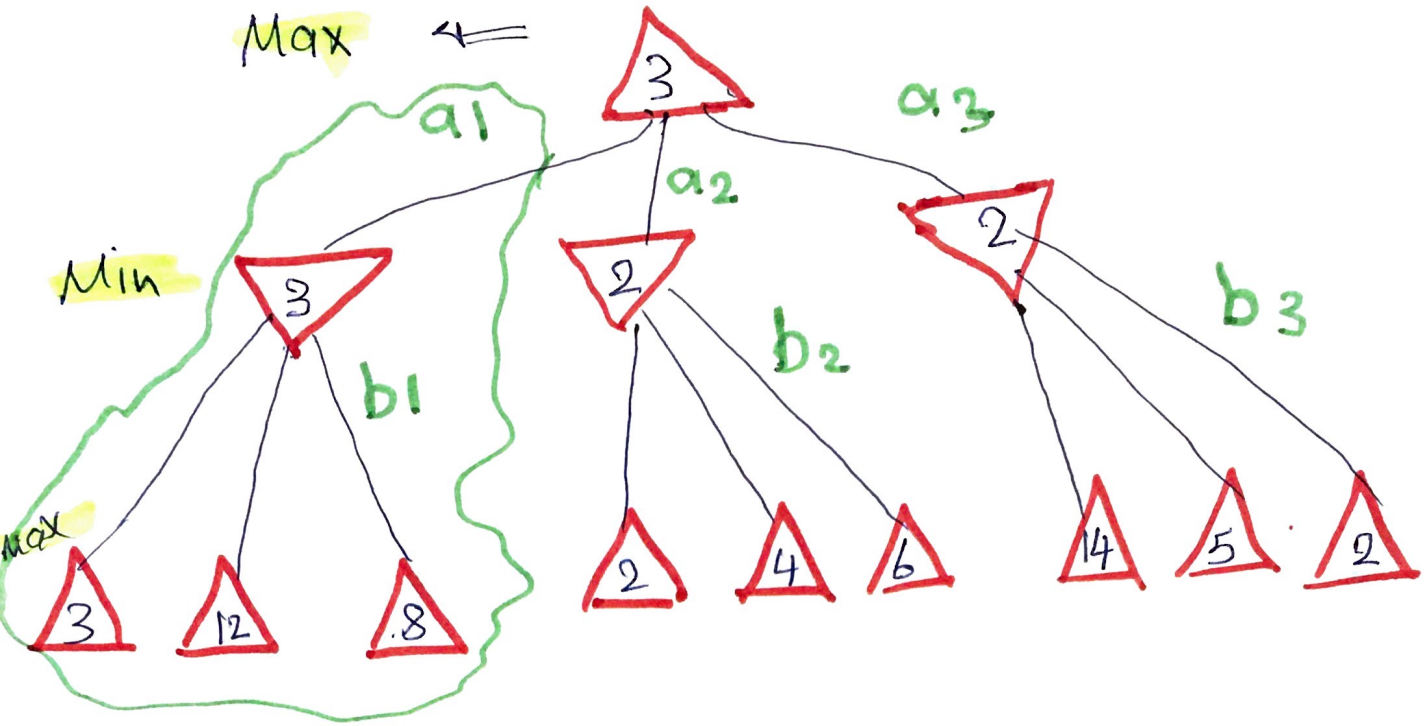

* ملاحظة △ معناها Max لأنه لفوق إلكت ، ▽ معناها Min

* ع يرجع طريق a1 b1

Example 4

كل لاعب كبار ل Max عشان يفوز.

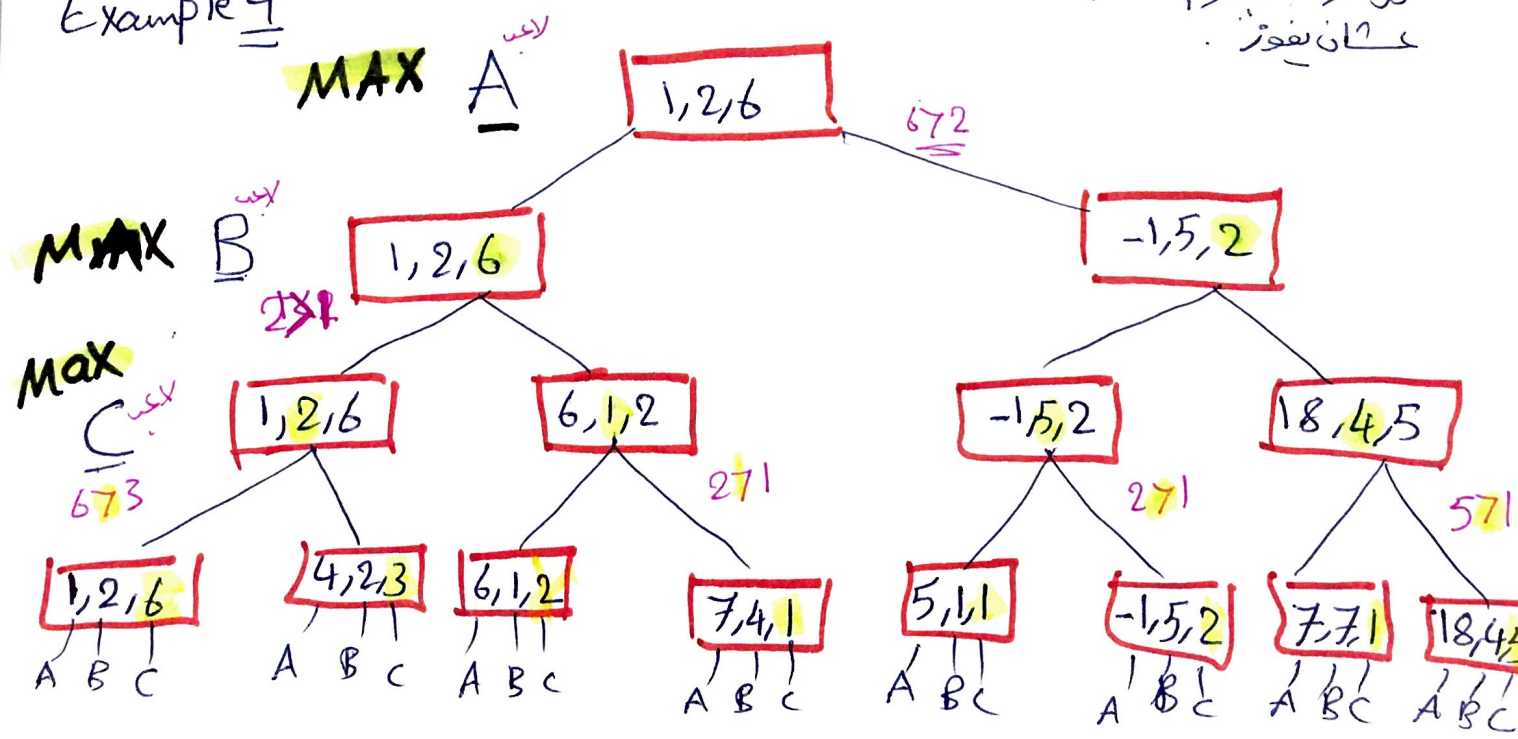

- C معناها بقارن بس مع ل C و ال C
- B معناها بقارن بس مع ل B's
- A بقارن بس مع A

بياخد ل MAX ← كل لاعب كبار ل (MAX) تبعه بعض ما بينهم بالأول

Artifical intelligence

topic تابع #16

* Game Theory

Alpha - Beta pruning • تسهل تقليل حجم الـ tree

* هي تطوير وتعديل على Min-Max بس بتختصر الوقت

Examples:

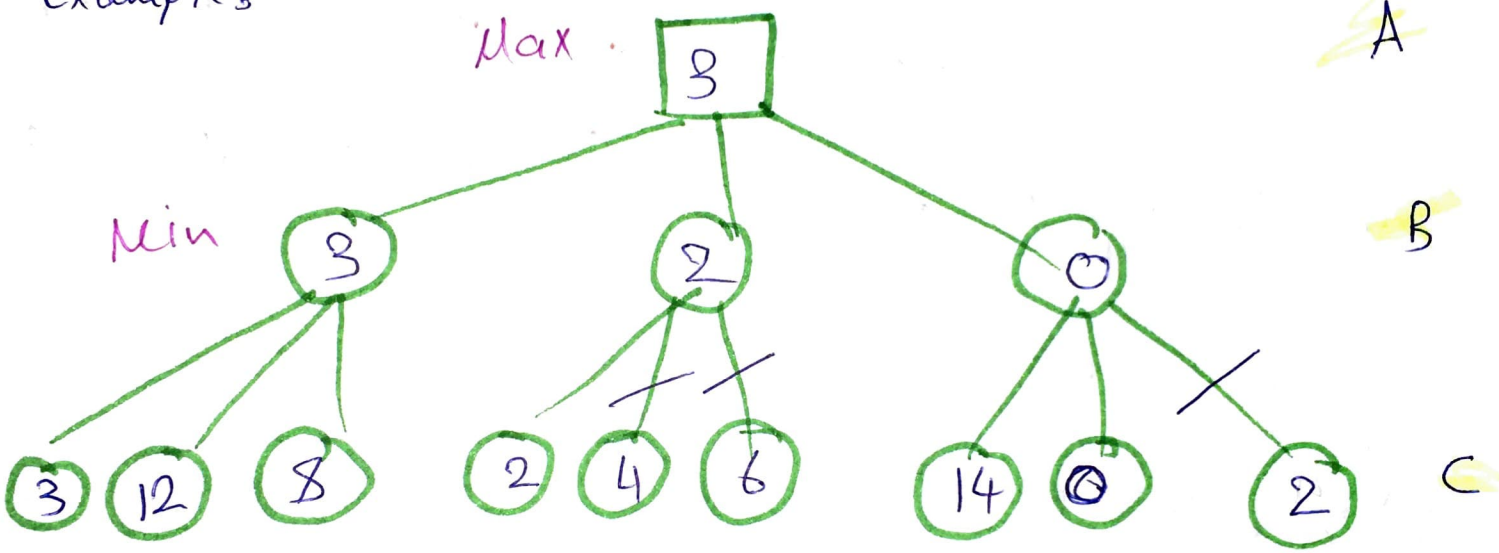

- كم عدد العناصر اللي تم فحصها فيه الخطوة C ⇐ 6

- أول اشي شفنا الـ Min اللي هو 3 لأول subtree بعدين الـ subtree الثانية شفنا أول رقم 2 يا أنه 2 أقل من 3 بسرعة نتجاره بدون ما نشوف شو جيه، بعدين الـ subtree الثالثة شفنا 14 بعدين 0 اخترنا zero متغير ما نطلع على 2 لأنه 0 أقل من 2 فاخترناه وانتهت من غير ما نطلع على اللي بعده

Example 2

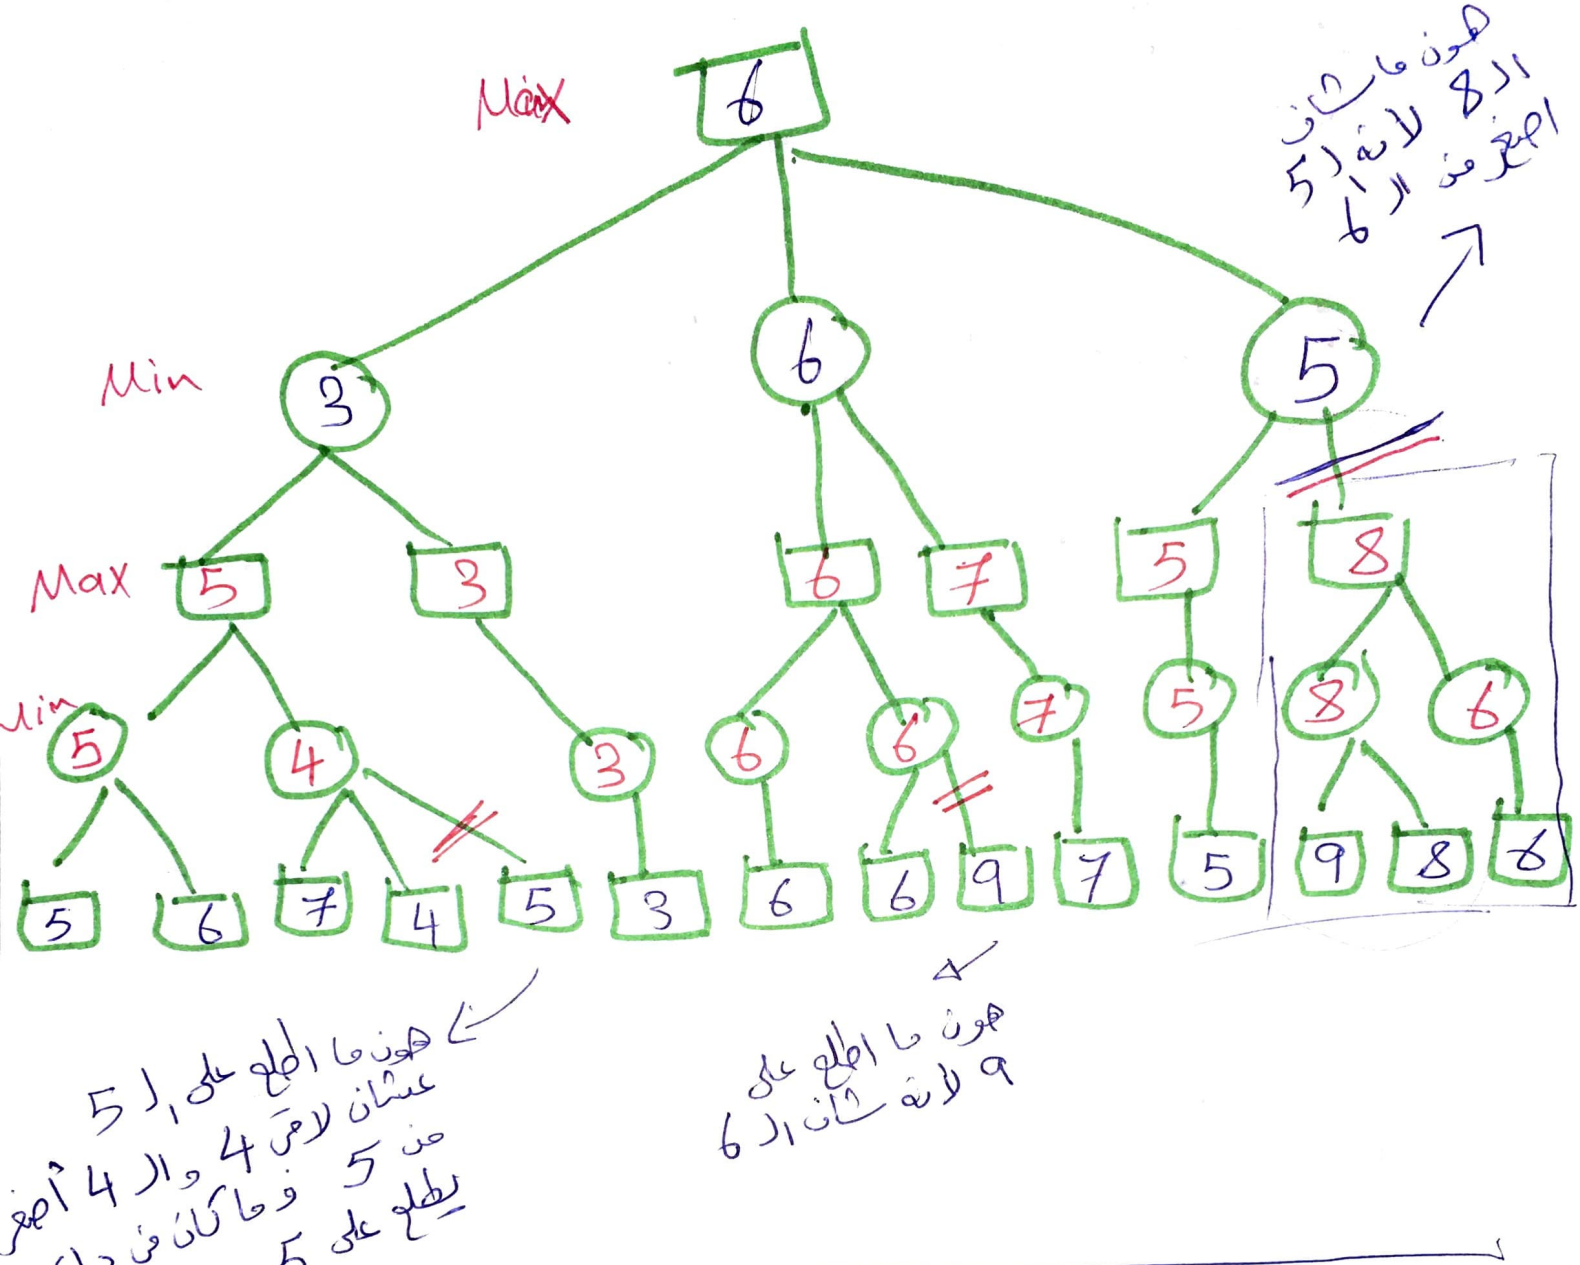

هون ما اطلع على 5 لان 4 و 4 اصغر من 5 فوكان في داعي يطلع على 5

هون ما اطلع على 9 لانه كان 6

هون ما اطلع على 8 لانه 5 اصغر من 6

Example3

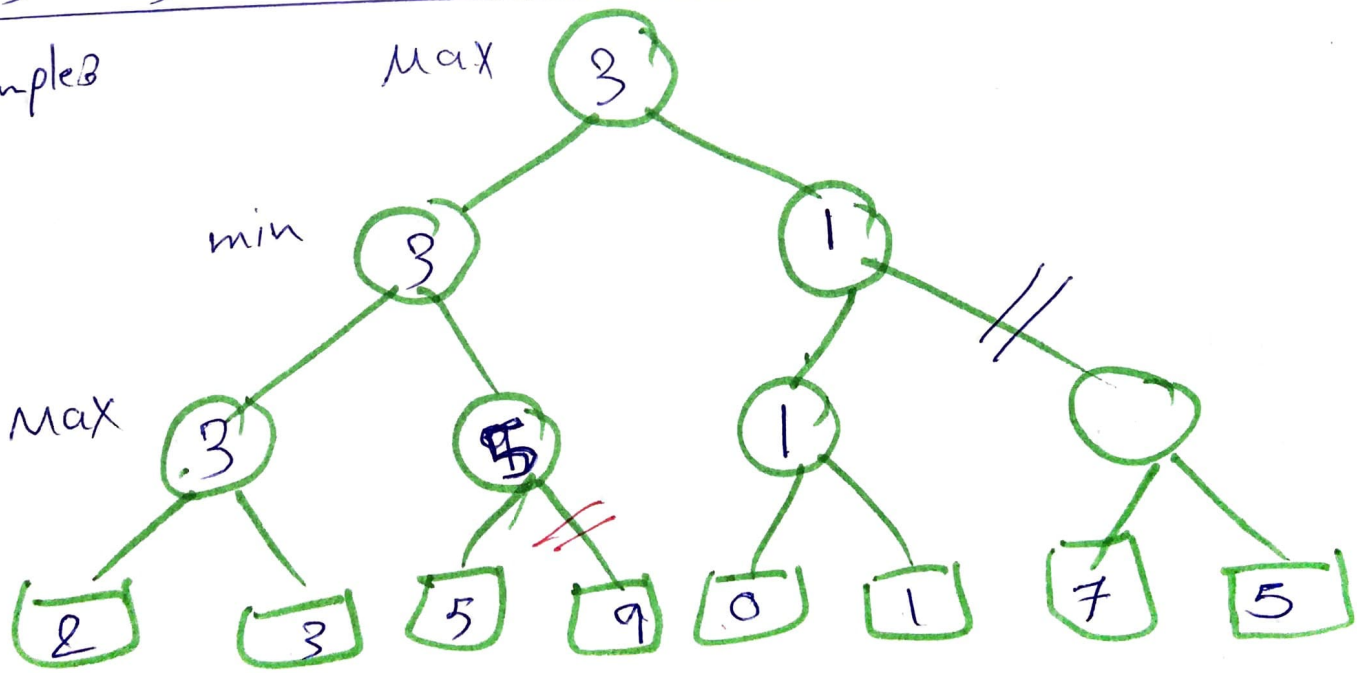

Type of Games:

* ① Perfect VS Imperfect information

معي معلومات كافية عن الطرف الثاني
Trex

هي معلومات غير كافية عن الطرف الثاني
زي (الهند) شدة ، ما بتعرف الطرف الثاني شو معه

② Zero Sum VS Non-Zero Sum

إذا أنا كسبت أنت خسرت، خاص هو خسارتك

نتعاون مع بعض على النجاح (الفوز)

③ Sequential VS Simulation

تتابعي

يعني ما بصير العب الا لما دورك ، ما بيجي دوري الا إذا لعبت عالدور

بجاربو فيتمس الوقت يعني ما بستنى الطرف الثاني يلعب عشان العب

④ Symmetric VS Asymmetric

لما يكون عندي Goal واضح
يعني الطريق واضح للنجاح

ما في طريق واضح
كيف بجمع الcoins ما بعرف كيف بجمعهم (الطريقة) ، يعني طريقة للفوز مختلف عن طريقه.

⑤ Cooperative VS Non-Cooperative

Aliances التحالف

تسمح بصير تعاون بين اكثر من شخص

ما بتسمح للتعاون ، زي الشطرنج

Game Theory :-

Nash Equilibruim.

- prisioner's delimma

① Payoff matrix.

	P2 cooperate	P2 betroy
P1 cooperate	(-1, -1)	(-3, 0)
P1 betroy	(0, -3)	(-2, -2)

Nash equ..

- هنا لصين سيجون مختلفة ① إذا اللصين ما اعترفو ← يعني نحكم سنة كل واحد

② إذا واحد اعترف وواحد ما اعترف

اي اعترف ما يسجن ولا سنة والي ما اعترف نحكم ٣ سنين

③ إذا اللصين اعترفو نحكم سنتين سنتين

* هون السالب لانه السجن خسارة .
* كلما كان الرقم أكبر كان أحسن

* نتعامل مع أعدة نتعامل مع الرقم الأول
* نتعامل مع الصفوف نتعامل مع الرقم الثاني

* أحسن حالة لما اللصين يعترفو على بعض

cooperate	coperate	-1, -1
betroy	coperate	0, -3
cooperate	betroy	-3, 0
betroy	betroy	-2, -2

Stag rabbit hunt.

فيه عندي Game في لاعبين بإمكان اصيد stag او rabbit
ال stag وزنه 4 كيلو وال rabbit وزنه 1 كيلو
ال stag ما بصير اصيده على انفراد ، ~~يعني~~ يعني لازم لاعبين
يصيدو stag وال 4 كيلو توزع على اثنين ، اذا صرح Rabbit
واللاعب stag أنا باخد 1 كيلو واللاعب الاخر لا ، إذا
أنا اخترت Rabbit واللاعب اختار Rabbit ال 1 كيلو بتوزع على اثنين

	P_2 Stag	P_2 Rabbit
P_1 Stag	(2,2)	(0,1)
P_1 Rabbit	(1,0)	$(\frac{1}{2},\frac{1}{2})$

2 Nash value
(2,2)
$(\frac{1}{2},\frac{1}{2})$

Example: Find Nash Equilibrium.

(8,7)	4,6
6,5	(7,8)

2 Nash
(8,7)
(7,8)

9,9	1,(10)
(10),1	(2),2

Nash
2,2

6,(8)	(4),7
(7),6	3,(7)

No Nash

(7),6	5,5
~~4~~,(5)	(6),4

Nash
=
7,6

* python part 1

platform

* Common Libraries in Anaconda (python)

(1) Numpy

- it has advanced math functions, scientific computing package and useful features for operations on n-arrays and matrices in python

(matrices و array الى بالنسبة Numpy)

(2) Scipy (science python)

- Library of software for Engineering and Science. contains modules for linear algebra (1), optimization (2), integration (3), and statistics (4).
- The main functionality of scipy is built upon Numpy and thus, it's arrays make substantial use of Numpy.

Numpy على مبنية scipy

linear Algebra : الى بالنسبة

(3) Pandas

- for quick and easy data manipulation, aggregation and visualization.

(4) Matplotlib

for visualization. للرسومات

(5) Seaborn

- for advanced visualization

Matplotlib على مبنية

(6) Scikit-learn (Science kit learn)

- for Specific functionalities like image processing and machine learning facilitation

libraries من

(7) Theano, Tensorflow, keras

- for Deep learning

(8) NLTK and Gensim Toolkit

for Natural language processing

machine learning

Management for Libraries. (python)

* Anaconda : الاساسي البرنامج

open source language.

Topic #17

* Natural Language processing (NLP)

معالجة اللغات الطبيعية

NLP is apart of Artifical intelligence which deals with human Languages.

قسم من الذكاء الاصطناعي تعامل مع اللغات البشرية

* Applications of NLP:

(1) Spell checking

الإملاء .

(2) Information Extraction

معلومة معينة بنا واياها هو يروح يدور عليها ويجيب ملخص عنها .

(3) Named Entity Recognition (NER)

بعطيه فقرة وبدل ما اذا اسم او رقم او فعل يغير كل كلمة هو موقعها في فكرة الإعراب وكل ال Apps بتذكرها لحتى يغير كلمة

(4) Summarization

يعطي ملخص عن تقرير كامل مش لموضوع معين .

(5) Seratiment Analysis

Happy or SAD انه اقرب من الشخص واذا الشخص يغير ال Feeling

(6) Speech Recognition .

التعرف على الاصوات

(7) chatbot الرد الآلي

(8) machine translation

(9) Voice Assistants .

(1) Siri Apple (2) Cortuma Microsoft (3) Google Assistant Google

(10) Social Media Monitoring

مراقبة ، انه في كلمات محددة بنادا على هاشتاقات سابقة بتعرف انها واجب قتلا .

(11) Making appointments

في حجز تذاكر الطيران وغيرها .

NLP components.

NLP

NLU
- Natural Language Understand.
- human language. → internal representation

NLG
- Natural Language Generation
- human language → representation

* NLU Ambiguity :-

① lexical Ambiguity:
the presence of two or more than possible meanings of singular words.
(semantic)

② Syntactic Ambiguity:
The presence of two or more possible meanings of a sentence or a sequence of words (Grammatical)

③ Refrential Ambiguity:
this kind of ambiguity arises when refering to something using pronoun

Examples

Example (1)

The fisherman went to the bank

بنك ← جنفة

- عند قراءة الجملة من قبل البشر يقدر اميز ف سهولة من سياق الكلمة
وهذا تحدي للحاسوب (الكمبيوتر)

Lexical

Example 2

عين ← الانسان
على
شربت من العين.

Lexical

Example 3

The chicken is ready to eat :

- الدجاجة جاهزة لكي تأكل
- الدجاجة جاهزة لكي تأكل

Syntactic (Grammical)

Example 4

Visiting Relatives can be boring

- زيارة الأقارب ممله
- الأقارب ممله.

Syntactic (Granitical)

Example (5)

Ahmad helped Rami He is a nice guy

(ضمائر) Rami : العبارة بين الحدود

ساعد احمد رامي لانه شخص لطيف

Refrential.

Topic#18

* Tokenization :-

is the process of breaking up String into tokens.

عملية تقسيم النص إلى عدد من المقاطع .

* Statistical language model:

it is a type of models that assigns probabilities to the sequence of word.

- أحد أنواع الـ model اللي بتحاول تتنبأ بالكلمة اللي ممكن تظهر، وبتحدد ظهورها sequence of word .
- شو احتمالية هاي الكلمات تكون مع بعض

مثال جاهزة بالنقاد شو احتمال يكون معها كلمة البطيخة وهيك !

* Statistical Language model

- **Bigram** : بقسمها 2 words
- **Trigram** : بقسمها 3 words
- **N-gram** : بقسمها 4 فأكثر .

Example

Given the following Statement:

"I Like object oriented programming"

① Apply the Bigram model to generate tokens?

مسميلي هاي كلمة كل كلمتين مع بعض.

[I Like] [like object] [object oriented] [oriented programming]

token

X = # of words in statement

# of tokens = X - N + 1

N: من عدد كلمات كل model

مثلاً Trigram = 3 ، Bigram = 2

عدد الكلمات اللي راح اطلعهم

# of tokens here? 5 - 2 + 1 = 4

② Apply the Trigram model to generate tokens

[I like object] [like object oriented] [object oriented programming]

# of tokens here = 5 - 3 + 1 = 3

③ Apply The 4-gram model to generate tokens?

[I like object oriented] [like object oriented programming.]

# of tokens here = 5 - 4 + 1 = 2

---

*why is important to assign probabilities to the sequence of words?

① allow group of word to be chunked together to form single Entities

- بسهلي اجمع مجموعة كلمات واصير اعاملها معاملة كلمة واحدة (single entity) مثلاً (شبكة تكنيم قطاع الاتصالات) بعاملة كأنها كلمة وحدة. (مش لازم اعرف المعنى وغير معكذا)

② Prediction of next words.

- مثلاً جملة البلعاد وكانت كلمة التطبيقية مش واضحة بتنبأ فيها وبعرفها

③ Spell-check error

قوانين ومعطلات لازم أعرفها

* N-gram model:

- predicate the accurance of aword based on its previous (N-1) words.

* Corpus:

كلما كان أكبر كان أسهل.

- Avery large Sample of ~~Earo~~ English Sentences.

* The probability of the word (wn) following.

$$\text{The word(wp)} = \frac{\text{Count(wp wn)}}{\text{Count(wp)}}$$

previous

احتمالية wn تتبع wp

* Example:

Given The following corpus:

1. He said Thank you.
2. He said bye as he walked through the door.
3. He went to San Diego
4. San Diego has nice weather.
5. It is raining in San Francisco.

① Calculate the probability of the word "Diego" coming after "San"

wn

wp

$$= \frac{\text{count("San Diago")}}{\text{count("San")}} = \frac{2}{3} = 66.6\%$$

② calculate the probability of the word "you" after "Thank"

wn

wp

$$= \frac{\text{count("Thank You")}}{\text{count("Thank")}} = 1 = 100\%$$

* TF-IDF

* TF (term frequency) = $\frac{\text{The number of a term appeared in the document}}{\text{Total numbers of term in that document}}$

* IDF (Inverse term frequency) = $\log\left(\frac{\text{total number of document}}{\text{Number of document with that term}}\right)$

Example:-

File 1: The car is driven on road

File 2: The Truck is driven on highway

Find TF * IDF for each word:-

word	TF		IDF	TF * IDF	
	F1	F2		F1	F2
The	1/6	1/6	$\log(2/2) = 0$	0	0
car	1/6	0	$\log(2/1) = 0.3$	0.05	0
is	1/6	1/6	$\log(2/2) = 0$	0	0
driven	1/6	1/6	$\log(2/2) = 0$	0	0
on	1/6	1/6	$\log(2/2) = 0$	0	0
truck	0/6	1/6	$\log(2/1) = 0.3$	0	0.05
road	1/6	0	$\log(2/1) = 0.3$	0.05	0
highway	0	1/6	$\log(2/1)$ 0.3	0	0.05

Topic#19.

*Stemming:-

- Normalize words into its base form or root form.

*example:-

affects, affection, affections, affecting, affected.

affect

* The stemming algorithms work by cutting the end or the begining of words taking into account a list of prefixes or postfixes.

*Common Examples of Stemmer:-

1. Port stemmer
2. Lancaster stemmer
3. Snowball stemmer

Example in Python (Port stemmer)

```
from nltk.stem import PorterStemmer
pst = PorterStemmer()
print(pst.stem("having"))
```

output: have

(PorterStemmer)

```
from nltk.stem import PorterStemmer
Pst = PorterStemmer()
Print(Pst.stem("give"))      => give
Print(Pst.stem("giving"))    => give
Print(Pst.stem("given"))     => given
Print(Pst.stem("gave"))      => gave
```

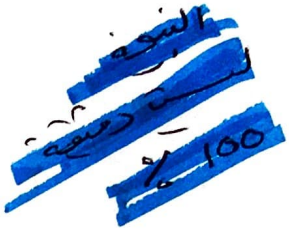

Example (3) (Lancaster Stemmer)

```
from nltk.stem import LancasterStemmer
m = LancasterStemmer()
print(m.stem("give"))    => giv
print(m.stem("given"))   => giv
print(m.stem("gave"))    => gav
```

* Lemmatization :-

it is necessary in NLP to have a detailed dictionary in which the algorithm can look into to find the basic form of word.

Example:

go, going, went —lemma→ go

شرح لـ videos المحاضرة

Testing
- train-test-split
- K-fold (عدد)

عدد المحاولات K مرات حسب الـ K
يعني ممكن تكون 1 أو 2 حسب K نفضل بعدد المحاولات

* نفضل العدد بين 5 و 10 مرات
  - أقل من 5 ما بستفيد اشي
  - أكثر من 10 بعيد عن المحاضر

* مثلاً K=10
قسم البيانات الي معي لـ 10 مجموعات وقبل ما تقسم عملي shuffle

Steps of k-folde

1. shuffle
2. divide data into k-groups

عندي 100 row قسمتهم على 10

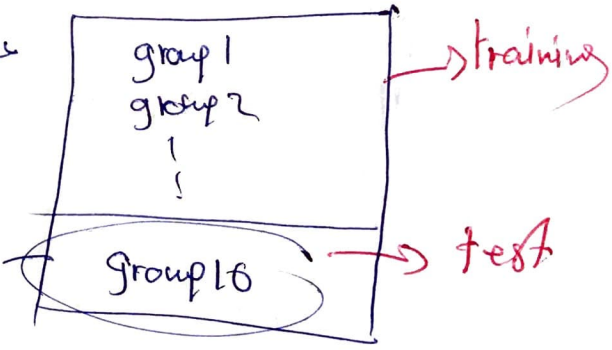

الأخيرة للـ test

نطلع الـ accuracy ونرجع نعيد مرة ثانية كمثل بدل ما كانت الـ test هذه للـ training والباقي تعبين كمثل الثانية الـ test والباقي training وهكذا
الـ Average بالـ accuracy تكون أدق من الـ accuracy الوحدة
حيطلع 10 نتائج accuracy وحسب الـ mean والـ std

Topic #20

*Robotocis :

an interdisiciplinary branch of engineering and Science that includes mechanical engineering, computer Science, and others.

* These technologies are used to develop machines that can substitute for humans and replicate human actions

^ Robots used in:

1. dangerous environments:

Many robots are built to do Jobs that are hazardous to people such as bomb detection, defusing bombs, finding survivors in unstable runs, and exploring mines and shipwrecks

2. Manufacturing processes

3. where humans cannot survive (in space, under water, in high heat and clean up and containment of radiation).

4. in STEM (science, technology, engineering and mathematics) as a teaching aid.

5. in medicine and human health, The advent of nanrobotics microscopic robots that can be injected into the human

* Robots can take any form but some are made to resemble humans in appearance

يمكن أن تأخذ الروبوتات أي شكل ولكن بعضها يصنع ليشبه البشر في المظهر

This is said to help in the acceptance of a robot in certain replicative behaviors usually performed by people

يقال إن ذلك يساعد في قبول الروبوت في بعض السلوكيات المتكررة عادة يقوم بها الناس

* Robotic sensing :

الإستشعار عن طريق الروبوت

is a subarea of robotics science intended to give robots sensing capabilities, that robots are more human-like ~~robotic sensing~~

إحدى قدرات الإستشعار الروبوتات كيف تكون الروبوتات آلة تشبه الإنسان

Robotic sensing mainly gives robots the ability to see, touch, hear and uses algorithms that require environmental feedback

تعطي الروبوتات القدرة على الرؤية واللمس والسمع والتذوق وتستخدم خوارزميات تتطلب ردود فعل

* The most popular language in robotics is :

- C/C++ (is an object oriented successor to the C Language)
- Python is also very popular due its use in machine learning and also because it can be used to develop ROS ~~pac~~ packages

× C programming and the Arduino microcontroller.
× Python and Raspberry Pi

ROS (Robot operating system) is a set of software libraries and tools that help you to build robot applications. you can also write your own programs for ROS : in C++ or python

robot applications لبناء

شرح ال videos

Video 1 (a) + video(b)

Spyder — شرح كيف أنزل Anaconda واله نستخدم برنامج

— أهم الأمور فيه ⇦ Anaconda

Home

Environments → بيئاتي اللي أنزلها libraries, packages

Learnings → كورسات python بعلم resource

Community → شو فيه أخبار عن Anaconda وشو الناس بتحكي عليها

Event Forum Social.

Video # 2

* عشان اكتب كود python بدي أختار Dataset اللي عجوبة بيانات أقرأها وأحللها واعملها training, test عشان إذا اجتني مرة كبيرة اقدر اتنبأ شو ال output الـ .

* ال Dataset اللي تختارها صون اللي هي iris.CSV

  ○ iris.CSV هو ملف Excel فيه مجموعة بيانات تحتوي على 150 صف

  كل صف فيه 4 مدخلات و output واحد ال output راح يكون

أنواع أزهار: Virginica, Versiocolor, setosa

* قصة ال iris هو بابا 150 زهرة مختلفة اجو اخذ ال lenght وال width ل اجزاء الزهور اللي هي petal و Spal

* أخذ 50 وردة Setosa , 50 Versiocolor , 50 Virginica وسجلوهم

الفكرة من الـ AI هنا انه إذا اعطاني ٤ صفات جديدة لوردة جديدة بإمكان الـ AI يتنبأ لأي وصيلة تنتمي

* وعشان اكتب كود python لـ operations على الـ data set

* basic operations over the data set

① Load The Data .

we are using pandas to load the data and explore the data both with descriptive statistics and data visualization

أول كود بكتبه عشان اجيب البيانات

package

```
import pandas
dataset = pandas.read_csv("C:\\Users\\Download\\iris.csv")
```

- dataset: عشان بدنا نقرأ من الـ iris.csv وبدنا نخزنها في dataset
- "C:\\Users\\Download\\iris.csv": الـ path اللي بدي أقرأ منه البيانات
- read_csv: بتعرف إنها بدها تقرأ ملف من نوع csv
- pandas: اسم الـ package
- dataset: بتعتبر object بتقدر تسميه اي اسم

ملاحظة: لما أروح اجيب الـ path واعمله copy ولما أروح paste لاعمله بنكتب بإيدي بيصير error

"C:\Users\Download\iris.csv" ✗

وهنا غلط بالـ python

بكل لغة backslash مش لازم تكون وحدة

1. "C:\\Users\\Download\\iris.csv" ✓
2. "C:/Users/Download/iris.csv" ✓

Video #3

أي ملف python بكون امتداده by default .py

تابع لـ operation .

(2) Dimensions of Data. (Attributes).

بكتب على الكود اللي قبل .

```
import pandas
dataset = pandas.read_csv("C:\\Users\\Download\\iris.csv")
print(dataset.shape)
```

Attribute ترجعلي عدد الصفوف وعدد الأعمدة بال iris.csv

output

```
In[1]: runfile - - - , wdir= - - -
In[2]: runfile - - - , wdir= - - -
(150,5)
```

150 عدد الصفوف، 5 عدد الأعمدة

```
In[3]:
  - - sepal_length sepal_width - - - -
0
1
2
3
4
```

إذا ترتبا فاضية head فاضية by default بجاب أول 5 صفوف

```
In[4]
```

sepal_length sepal width - -

count عدد الصفوف داخل العمود
mean المتوسط الحسابي
std
min
25%
50%
75%
max

كل عمود معاه 8

(3) Top rows of Data.

بكتب للكود

```
print(dataset.head(10))
```

- إذا ترتبا فاضية بطبعلي أول 5 صفوف by default
- إذا 10 بطبعلي أول 10 صفوف
- إذا حابب استعرض اول بيانات معينة من الصفوف نستخدم method اسمها head

(4) Statistical Summary.

بكتب للكود

```
print(dataset.describe())
```

بترجع لكل columns بالداتا فريم بطبعلي عن كل column count, mean, بترجع بالإكسيل

count بطبعلي sepallength مثلا بترجع

(5) Class Distribution.

```
print(dataset.groupby('variety').size())
```

output

```
variety
setosa      50
Versicolor  50
Virginica   50
dtype: int64
```

- بنعمل group by على عمود الـ variety
- بعد كده بنعمل size عشان نعرف كام صف في كل واحد
- بنقدر نعمل كده على أي عمود تاني زي sepal_length

Video #4

(6) Create a Validation Dataset.

- الـ dataset بتاعة الـ ML لازم نقسمها الأول لـ Validation data و Training data
- لازم نعزل الـ input بتاع الـ training عن الـ testing في مكان، والـ output بتاع الـ training في مكان تاني، والـ input بتاع الـ testing في مكان، والـ output بتاع الـ testing في مكان تاني.

كتابة على code

ملاحظة: الـ values بس لهم لازم يكون آخر عمود في الداتا بتاعتك

- X_train : input columns (for training)
- X_Validation : input columns (for validation)
- Y_train : output column (for training)
- Y_Validation : output column (for validation)

الكود:

```
from sklearn import model_selection
array = dataset.values
X = array[:, 0:4]
Y = array[:, 4]
Validation_size = 0.20
seed = 7
X_train, X_validation, Y_train, Y_validation = model_selection.train_test_split(X, Y, test_size=validation_size, random_state=seed)
```

- sklearn: library
- model_selection: class موجود في sklearn
- dataset.values: بترجع الداتا كلها Array
- X: كل الأعمدة اللي قبل آخر عمود (input)
- Y: آخر عمود (output)
- 0:4: من 0 لحد 4 (4 not included)
- Validation_size = 0.20: 20% للـ validation
- seed = 7: متغير بسيط عشان النتيجة تبقى ثابتة
- train_test_split: بتقسم الداتا

- الـ Array بتاعة الـ X قبل الفاصلة كل الصفوف وبعد الفاصلة الأعمدة
- الـ Array بتاعة الـ Y قبل الفاصلة كل الصفوف وبعد الفاصلة العمود الأخير

video #5 + video #6

train_test_split

method جاهزة بالمكتبة sklearn بتقوم بتقسيم البيانات training و testing
وعشوائيا بتقسم البيانات الموجودة معاي جزء منها يكون لل train وجزء لل test

ف الـ output بيطلعلي على شكل tuple

* parameters of train_test_split:
  1. Input columns (X)
  2. output columns (Y)
  3. How many rows for training, and how many rows for testing?

يعني من الـ 150 صف كم صف أخليه للـ training وكم صف أخليه للـ testing
وما بنقلهم بشكل ثابت

```
train_test_split(X, Y, test_size = validation_size, random_state = seed)
```

test_size ثابتة ما بتغير اسمها بأي مابيل

* حسب الاسم الـ test_size
لو كان N بقصد N
متغير أنا بعرفه
* لما عرفتها

test_size = 20% يعني خلي 0.20
test لـ 30 صف يعني

* بشكل عشوائي بياخد
training صف بسمى 120 و testing صف بسمى 30

أو مجرد العقبة مباشرة 0.20 يعني ما استخدم متغير

random_state = seed
إذا اختلف الـ seed بتختلف الأرقام
فأي أي دلالة للأرقام
كل مرة بجيبلي نتيجة غير عن اللي قبل

return values of this method: (task)

X_train, X_validation, Y_train, Y_validation

بإمكاني اسميهم متشان

تم استدعاؤها من model_selection

```
print(X_train.shape)
```

output
(120, 4)

يعني إنه عندي بالموجودة بـ X_train عندي من 120 صف و 4 أعمدة

زدنا كتبنا

Print(Y_validation.shape)

output
(30,)

Video 7+8

(7) Make predictions:

Some examples of common algorithms used for Classifications

1. KNeighborsClassifier
2. LogisticRegression
3. Naive Bayes
4. Support vector Machine
5. DesicionTree Classifier

Algorithm كل
الـ طريقة
وحش بشرط انه
نتوصل لنفس العلاقة.
كل واحد اله دقة معينة

ins.csv
↳ Discrete values
لا ordered

تكملة الكود

```
from sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier()
knn.fit(X_train, Y_train)
predictions = knn.predict(X_validation)
from sklearn.metrics import accuracy_score
print(accuracy_score(Y_validation, predictions))
From sklearn.metrics import confusion_matrix
print(confusion_matrix(Y_validation, Predictions))
```

- object: اسم متغير
- KNeighborsClassifier(): method
- parameters
- predictions: متغير
- X_train, Y_train: نتوقع شو الـ output, 30 صف اكوردين
- X_validation: testing
- predictions: مخزن فيها بالنتيجة
- predictions: بنتيجة حتكون 30 بصف واحد
- accuracy_score: معنى كم نسبة تطابق القيم الحقيقية مع المتوقعة اكوردات

output
0.90
بالنسبة
لـ 30صف

- اذا عبرت seed=20

output
0.96666

الخطوات بشكل عام

اي بكامنها Python

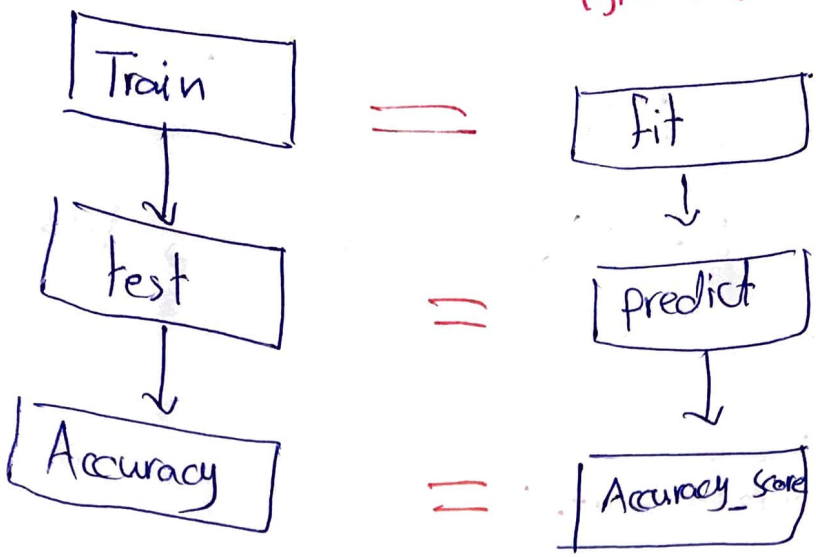

لازم اعلامات الخطوات في كل ML

* the method **fit** is used for training.

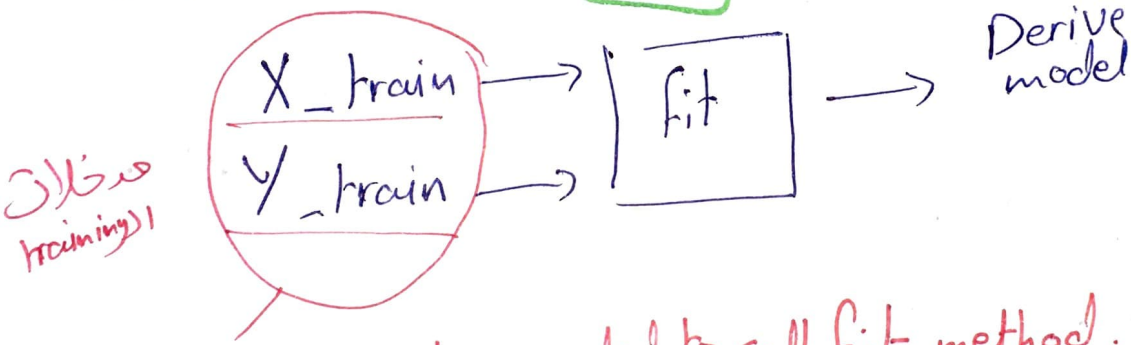

2 main parameters needed to call fit method.

* the method **predict** is used for testing:

only main parameters needed to call predict method.

X_validation لازم تكون
نفس انا شو بيمر المتغيرات

* The method accuracy_score is used for evaluating the accuracy.

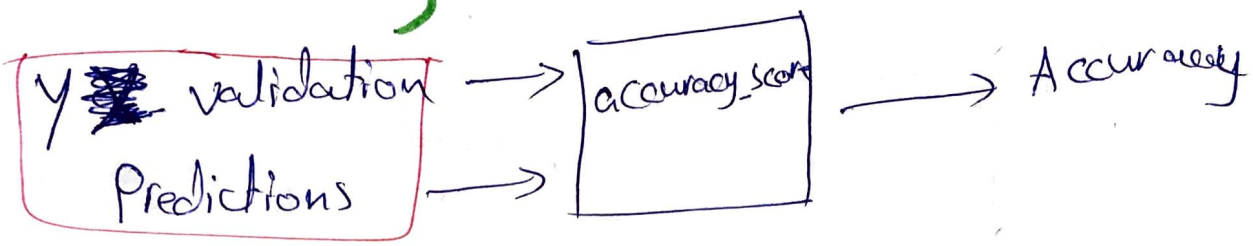

2 main parameters needed to call accuracy_score

Y_validation:

predictions: Algorithm

python part 2

video 9

Univariate Plots:

dataset.hist()

histograms

output

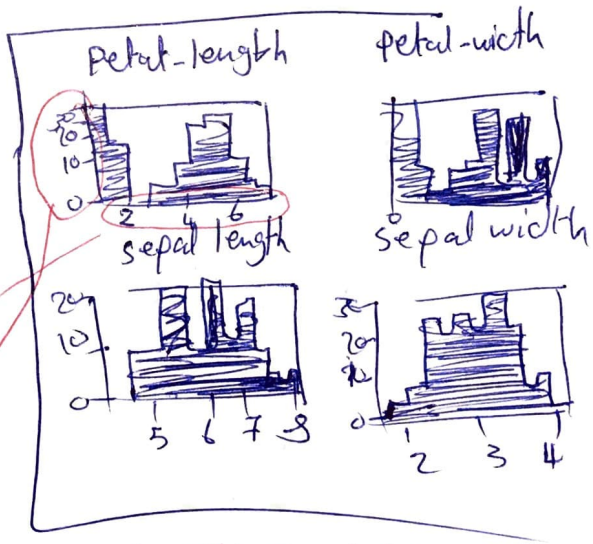

Multivariate Plots.

From pandas.plotting import scatter_matrix

scatter_matrix (dataset).

output

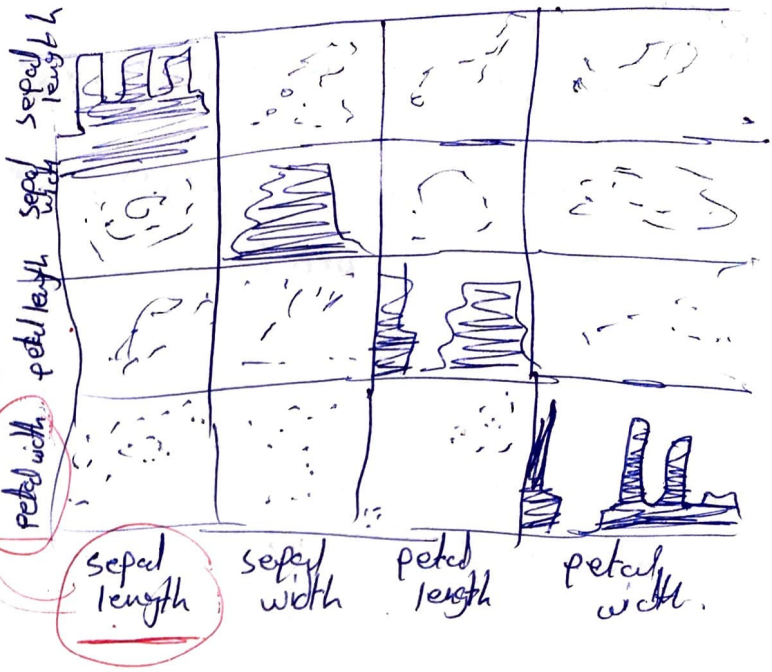

Generating 2D classification dataset (video 10)

From sklearn.dataset.samples_generator import make_blobs

X, y = make_blobs(n_samples=100, centers=2, n_features=3, random_state=1)

For i in range(len(X)):

    print("X=%s, y=%s" %(X[i], y[i]))

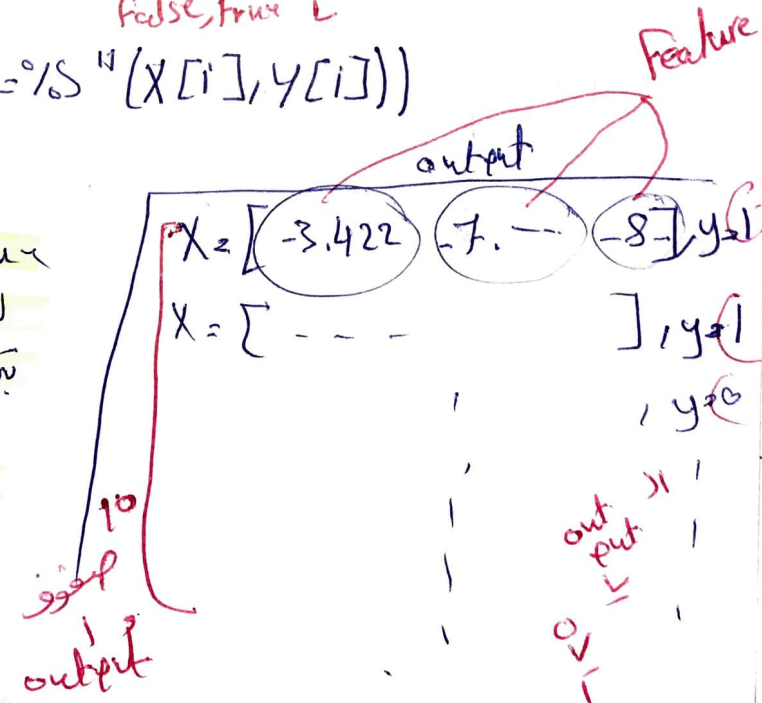

* Generating 2D regression dataset

Video

class — method

```
From sklearn.datasets import make_regression
X,y = make_regression(n_samples=4, n_features=2, noise=0.1)
for i in range(len(X)):
    print("X=%s, y=%s" %(X[i],y[i]))
```

n_samples: عدد الـ rows
n_features: عدد الـ input columns
noise: الـ output (القيم) طبيعة
0.1 = الـ std

output: continues range أو classification: discrete value

noise default: 0.0

output: عدد الـ rows

```
X=[0.4  -1...],  y=25.49
X=[--   --  ],  y=--
X=[--   --  ],  y=--
X=[--   --  ],  y=--
```

4 صفوف

```
model = LogisticRegression()
```

Video 12

algorithm هو classification يستخدم
وهيك طريقة استخدامها

```
model = LinearRegression()
```

Regression أبسط) — Rigression — common algorithm

python (part 4) :-

video 13

k-fold cross validation :-

```
dataset = pandas.read_csv("C:\Iris_dataset.csv")

array = dataset.values
X = array[:, 0:4]
Y = array[:, 4]

From sklearn import model_selection
kfold = model_selection.KFold(n_splits=10)
From sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier()
cv_results = model_selection.cross_val_score(knn, X, Y, cv=kfold)
msg = "Mean = %f STD = %f" % (cv_results.mean(), cv_results.std())
print(msg)

from sklearn.tree import DecisionTreeClassifier
dtc = DecisionTreeClassifier()
cv_results = model_selection.cross_val_score(dtc, X, Y, cv=kfold)
msg = "Mean = %f STD = %f" % (cv_results.mean(), cv_results.std())
print(msg)
```

output

```
Mean = 0.933  STD = 0.0842
Mean = 0.933  STD = 0.0842
```

Confusion Matrix

Example(1)

we have 100 person

- label(1) refers to : has cold/flu
- label(0) refers to : has NOT cold/flu

عندنا 100 شخص بعضهم مصابين بالبرد و الباقي غير مصابين

actual data

90: have not cold/flu

ما عندهم اصابة بنزلة البرد 0

10: have cold/flu

عندهم اصابة بنزلة البرد 1

predicted data algrithm (accuracy 95%)

95: have not cold/flu

5: have cold/flu

accuracy 95% غير كافية لانه البيانات غير متوازنة balance

× Confusion matrix

TP=5	FN=5
FP=0	TN=90

5 اللي عندهم البرد (1) بس الخوارزمية حكت عنهم انهم مصابين بس طلعو مش مصابين

في حالة توقع negative وكانت صحيحة 90 منهم اطلعت صحيحة

$$\text{accuracy} = \frac{TP + TN}{TP+TN+FP+FN} = \frac{5+90}{5+5+90} = 95\%$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{5}{10} = 50\%$$

يعني صحيح 5 من اصل 10 قد يعني اللي مصابين فعلا كويس

$$\text{precision} = \frac{TP}{TP+FP} = \frac{5}{5+0} = 100\%$$

اذا 5 مصابين بالبرد وكلهم عندهم مصابين بالبرد صحيح

*Confusion Matrix

تتكون من ٤ أرقام فيها موجب وسالبين

	Class 1 Predicted	Class 2 Predicted
Class 1 Actual	TP	FN
Class 2 actual	FP	TN

TP (True Postive) : observation is postive and is predicted to be postive

FN (False Negative) : observation is postive, but predicted negative

FP (False Postive) : observation is negative. but predicted is postive

TN (True Negative) : observation is negative, and predicted is negtive.

$$\text{accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{Recall} = \frac{TP}{TP+FN}$$

$$\text{precision} = \frac{TP}{TP+FP}$$

*Recall : High Recall indicates the class is correctly recognized (small number of FN)

لا تكون قيمة الـ Recall عالية إلا لما يكون الـ FN قليل جدا

*Precision : high precision indicates an example labeled as postive is indeed postive (small number of FP)

لا تكون الـ Precision عالية إلا لما يكون الـ postive فعلا postive

python program :

```
actual = [1, 1, 0, 1, 0, 0, 1, 0, 0]
predicted = [1, 0, 0, 1, 0, 0, 1, 1, 0]
results = confusion_matrix(actual, predicted)
print 'confusion_matrix :'
print(results)
print accuracy_score(actual, predicted)
```

Example 2

Given the following table, suppose that 1 represent positive
0 represent negative

output of actual data	Output of predicted data
1	1
1	0
0	0
1	1
0	0
0	0
1	1
0	1
0	1
0	0

1. Find confusin matrix
2. Find the accuracy
3. Find the precision.
4. Find the recall.

TP = 3	FN
FP	TN

3	1
2	4

① TP = 3 FN = 1 (positive negative) FP = (negative positive) TN = (negative negative)

② Accuracy = $\frac{TP+TN}{TP+TN+FP+FN} = \frac{3+4}{10} = \frac{7}{10} = 70\%$

③ Recall = $\frac{TP}{TP+FN} = \frac{3}{3+1} = \frac{3}{4} = 0,75 = 75\%$

④ precision = $\frac{TP}{TP+FP} = \frac{3}{3+2} = \frac{3}{5} = 0,60 \quad 60$

Python (part 3)

K- fold Cross Validation:

using train/test method to estimating the skill of the procedure on unseen data sometimes a high variance, this means that when it repeated it gives different result, often very different result.

Cross Validation is another method to estimate the skill of a method on unseen (Testing) data. like using train_test split.

Cross validation is a statistical method used to estimate the skill of machine learning models. it's commonly used in applied machine learning to compare and select a model for a given predictive modelling problem because it is easy to understand, and easy to implement

* performance measure:

① we calculate mean of these measure to performs Average

② we calculate standard deviation of how will the skill procedure expected to vary in practice

* resampling methods:

are statistical procedures for sampling a dataset and estimating unknown quantity

لأخذ عينات من dataset وتقدير لكميات مجهولة

① train_test_split
② k-fold cross validatio

} resampling methods.

The general procedure:

1. shuffle the dataset randomly
2. split the data set into k groups.
3. For each unique groups:
   1. take the group as hold out or ~~slet~~ test data set
   2. Take the remaining groups as a training data set
   3. fit a model on the training set and evaluate it in the test set
   4. retain the evaluation score and discard the model.
4. Summarize the skill of the model using the sample of model evaluation scores.

---

٣ أنواع من Classifier

1. kNeighbors Classifier
2. DesicionTreeClassifier
3. Logostic Regression