Text book:
Artificial Intelligence: A modern APProach.
Authors: Russell & Norvig.
3rd edition.

subject name

1. AI aPPlications: P.g 28 section 1.4

⊙ Game Programming :-
DeeP Blue (software) → انشأته → IBM
→ من خلاله تم هزيم بطل العالم بالشطرنج

⊙ sPam Fighting :- (غير مرغوب)

⊙ Robotics :-
iRobot (شركة) → صنعت → Vacuum cleaners (مكنسات كهربائية)

⊙ Machine Translation (الترجمة) :-
one word → مخزنة على → DataBase
Statements → نتائج → AI

⊙ sPeech Recognition (التعرف على الكلام المنطوق) :-

⊙ Robotic vehicles :-

2. What is AI :- P.g 1 section 1.1

* Artificial Intelligence :- the ability of computers (machines) to ① act and ② think humanly, and to ③ act and ④ think rationally.

① act humanly :-

1950 Turing (بيل)

Turing Test)

→ عبارة عن test يتم من خلاله machine و human اعطاء مجموعة أسئلة للإجابة عنها وبعد الإجابة عن الأسئلة يتم تسليم الشخص يسمى الفاحص الإجابات ، فإذا لم يتمكن الفاحص من معرفة او التفريق بين اي الإجابات اجابتها الـ machine واي الإجابات اجابها الـ human وبالتالي هذه الـ machine تحتوي على تقنيات الـ AI . [Pass the test]

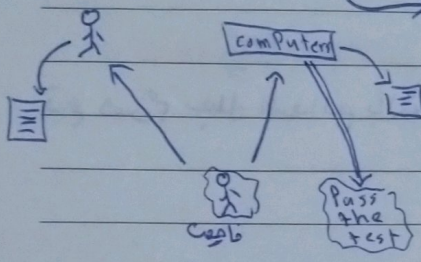

② think humanly :-

Cognitive Science. علم المعرفة

③ think Rationally :- عقلاني

logic

Ex :- All metals expand when heated.

- Iron is a metal.

then ⇒ Iron expand when heated.

④ Act Rationally :-

ambiguous environment.

3. Test Problems :- P.g 71 + 72

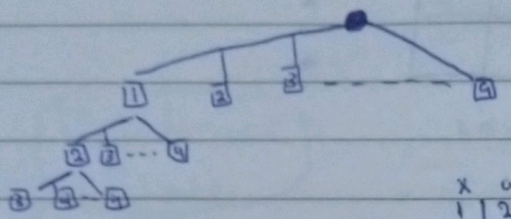

XO Game

X	O	
1	2	3
4	5	6
7	8	9

Knowledge represented in a tree or graph

using ⟹ Search (البحث في البيانات)

Search Algorithms

algo 1, algo 2, algo 3

Test Problems

* To evaluate the different algorithms, we have two common test Problems :-

1. N-Puzzle.
2. N-Queens.

1. N-Puzzle:

3-Puzzle (2^2-1)
8-Puzzle (3^2-1)
15-Puzzle (4^2-1)
31-Puzzle (5^2-1)
⋮

	1
2	3

3-Puzzle

Goal-State

2	1
	3

initial-state

→ Solution: move block 2 down.

	1	2
3	4	5
6	7	8

8-Puzzle

Goal-State

[2] N-Queens :-

3-Queens
4-Queens
5-Queens
6-Queens
⋮

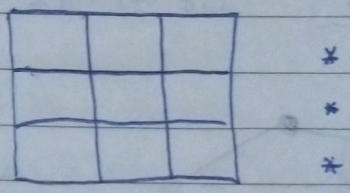

3-Queens

* وضع Queens في مربع واحد بحيث لا تهاجم Queen Queen وأمن لا يهاجم Queen أفقيا ولا قطريا.

Goal : to Place all Queens with no attack any other.

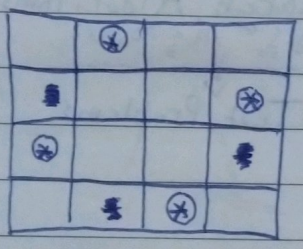

4-Queens

Solution ← solution for Queens Problems.

- incremental formulation
- complete state formulation

Evaluation of algorithms P.g 80

- Completeness
  - Does this algorithm gurantee to find a solution when there is a one?
- Optimality من ناحية الأداء
  - Time Complexity
  - Space Complexity

4. Uninformed Search :- P.g 81

Search

Uninformed (Blind)

كل ما اوصل لنقطة بسأل هاي هل وصلت لـ Goal ؟
(لا يوجد معلومات تخبرني اني قريب / بعيد عن الـ Goal).

Informed (Hurستic طلبي)

- كل ما اوصل لنقطة بسأل هاي هل وصلت لـ Goal ؟
- مع كل نقطة بزورها في معلومة معينة بتخبرني اني قريب / بعيد عن الـ Goal

المعلومة اي راح تساعدني بالوصول لـ Goal

Uninformed Search Examples

Breadth-First-Search (BFS)

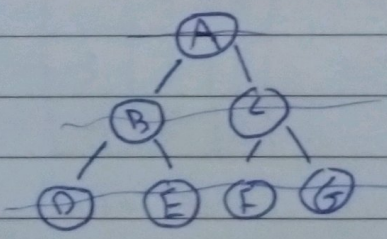

ABCDEFG

Depth-First-Search (DFS)

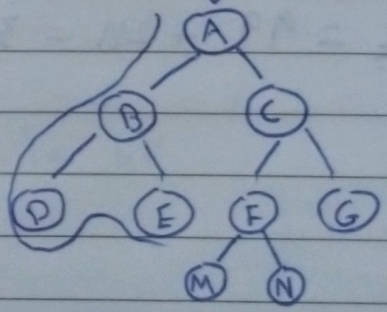

ABDECFMNG

5. Uninform Search (Cost) — P.g 84

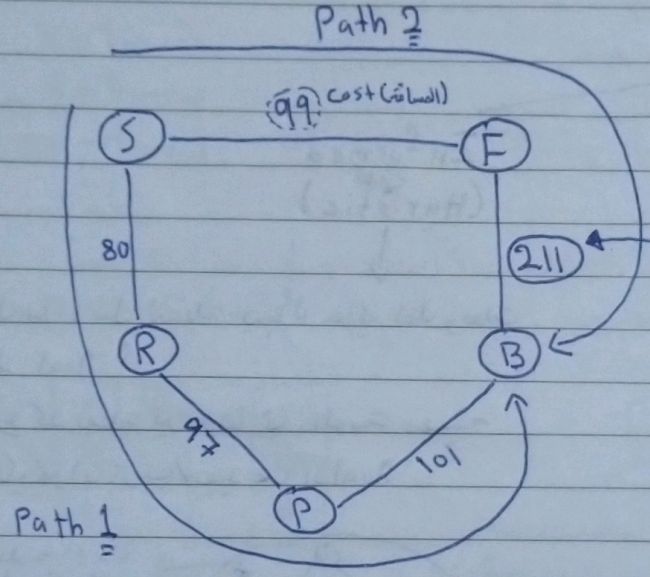

- حماية المعلومة غير مفيدة انو انا قريب/بعيد من الحل بس بتعطيني الـ cost ولذلك تعتبر uninformed

* from city "S" to city "B" :

Path 1 = 80 + 97 + 101 = 278 (cost لـ)

Solution : S R P B (Path 1).

- Path 2 = 99 + 211 = 310

هدى / ظلي / تنبوء / توقع

6. Heuristic Functions :- P.g 102

other names:
- or → Evaluation Functions (تقيم) — لأنه بتقيملي انو قريب / بعيد عن الحل
- or → Fitness Function

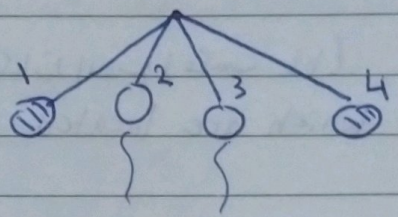

* عندي 4 احتمالات (1, 2, 3, 4) بس (1 و 4) بوصلوني للحل فبستخدمهم مشان اوصل للحل وما بعرف على الاحتمالات (2, 3) فقلت الاحتمالات بدي 4 و 2 اللي قيمة (1 و 4) وراح بوصلوني للحل بشكل افضل (اسرع) ⟸ "more Promising" (واعد).

* النقطة (1 و 4) سيمون "more Promising" لانهم راح بوصلوني للحل اسرع.

8-Puzzle Problem:-

	2	5
3	7	1
4	6	8

initial State.

- more '2' to left
- more '3' to up

	1	2
3	4	5
6	7	8

Goal-State

* مقاييس/معايير مشان نشوف انو قربنا/بعدنا عن الحل وهي عبارة عن (functions) :-

h1 :- The number of misPlaced tiles. (الأقل) — عدد المربعات/البلوكات اي شي بمكانها الصح

h2 :- The sum of distances of all tiles from the goal-State. (الأقل) — مجموع المسافات (كم مجموع الخطوات اللازمة أحركها مشان اوصل لمكان الصح)

h3 :- The number of tiles which are located in the correct Place. (الأكثر) — عدد المربعات الموجودة بمكانها الصح (عكس h1)

* 8-Puzzle Problem :-

	2	5
3	7	1
4	6	8

initial-State

$h1(n) = 6$

- more '2' to left. — $h1(n) = 6$ ✓ (باخذ الرقم الاقل)
  - $h2(n) = 9$
  - $h3(n) = 2$ ✓ (باخذ الرقم الاكبر المربعات بمكانها الصح)
- more '3' to up. — $h1(n) = 7$ X, $h2(n) = 9$, $h3(n) = 1$ X

$h2(n) = 2+1+0+2+1+1+1+0 = 8$

$h3(n) = 2$

Fitness Function
- Cost Function (المعيار بحاول يكون اقل ما يمكن مشان يوصل لـ 0 مثل h1 و h2)
- Objective Function (بزيد الرقم مشان اقرب للحل مثل h3 more كل ما كبر الرقم بكون Promising)

مشان أقيس المسافة بين العقد نستعمل معيار الـ cost Function

* Applying heuristic function on n-queens Problem:-

- عدد الملكات المتقاطعة مثلاً: يعتبر اني قريب/بعيد عن الحل

h1(n) = The number of attacking pairs of queens (cost) — (يريد يحاول اقلها ما يمكن).

كلما زاد → تكون امثل

h2(n) = The number of non-attacking pairs of queens (Objective).

Ex:

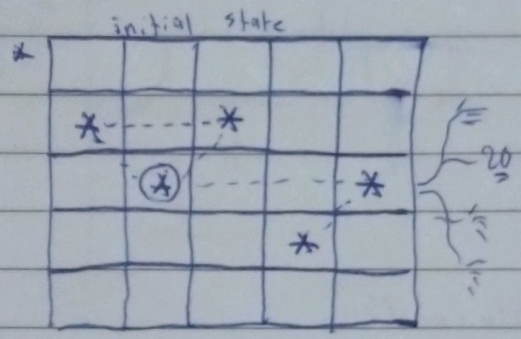

h1(n) = 2+0+2+1 = 5

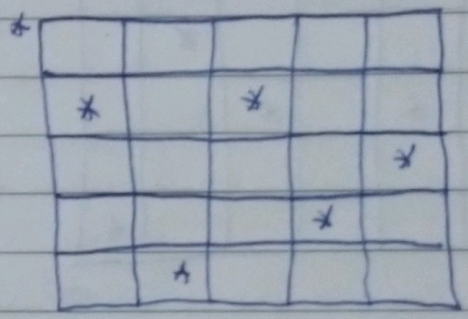

h1(n_next) = 1+0+1+0 = 2

(كلما قل cost ما قربت من الحل)

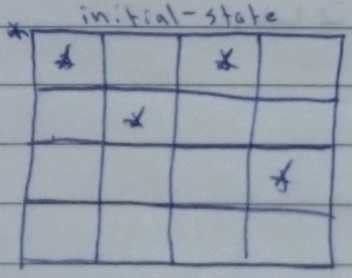

h2(n) = 3+0+0 = 3

rules: 4-queen: 3+2+1 | 5-queen: 4+3+2+1 | 6-queen: 5+4+3+2+1

→ Max-value of h2(n):

$$\sum_{i=1}^{i=n-1} i$$

rule

مثال اوجد الحل المثالي (اكبر منه ← h2)

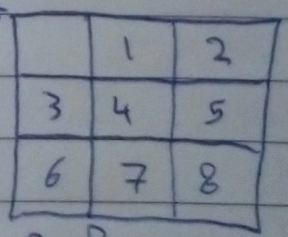

8-Puzzle

Max number of h3(n) = 8

n-Puzzle (target) = (n)

15-Puzzle ⇒ target = n = 15

~~* Representation~~

* Representation of n-Queens in Programming :-

- 2D arrays
- String representation

Ex :

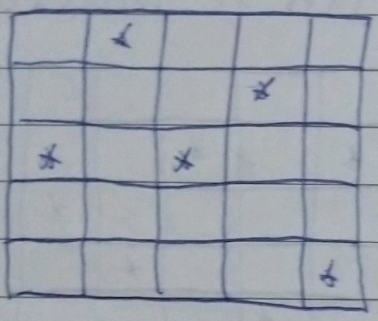

(a) Represent the 5-Queens Problem in the figure using 2D array.

Soln :-

0	1	0	0	0
0	0	0	1	0
1	0	1	0	0
0	0	0	0	0
0	0	0	0	1

1 = مكان وجود الـ Queens بنفط

والباقي 0

(b) Represent the 5-Queens Problem in the figure using string representation.

Soln :-

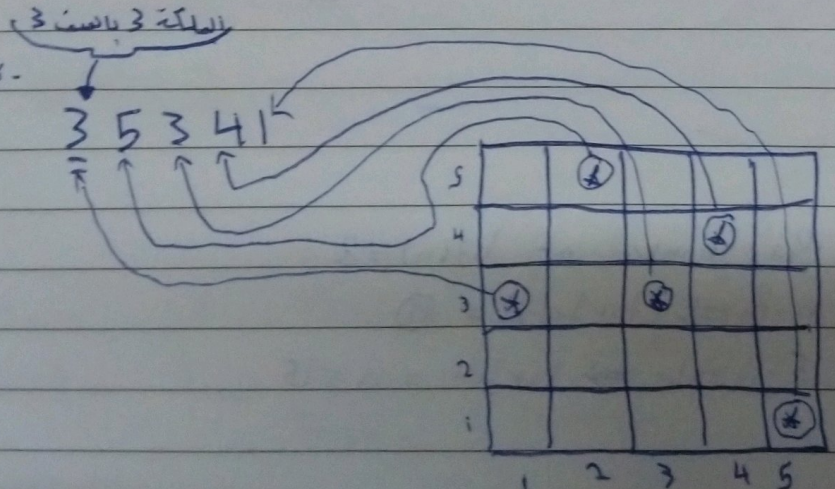

7. Search Space P.g 120+121

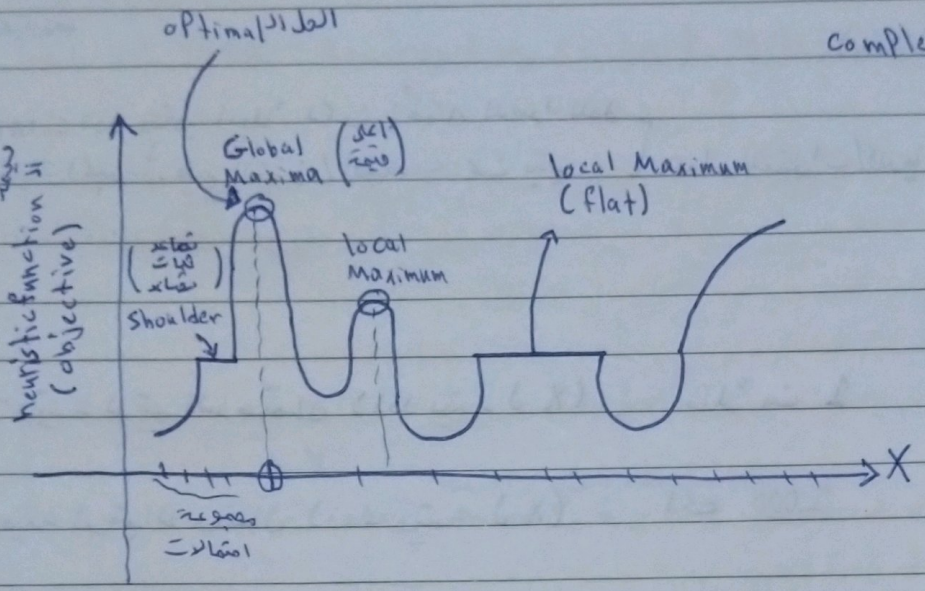

* كل complete هو optimal

* complete ← يوجد حل بس مش شرط يكون الـ optimal.
* optimal ← يوجد حل وهذا الحل هو الحل المثالي.

8. Hill Climbing Algorithm :-

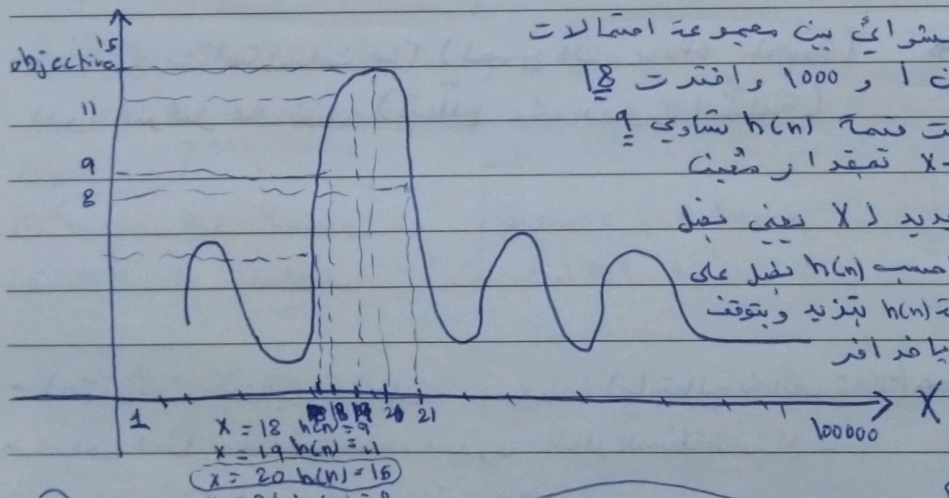

* فكرته انو يختار احتمال عشوائي بين مجموعة احتمالات مثلاً كان معي احتمالات بين 1 و 1000 واقتدت على بحسبلو h(n) وفرضاً طلعت قيمة h(n) تساوي 9 بعدها بزيد على الـ X-axis تمقدار معين وبحسبلها h(n) للعينة الجديد لـ X بعين بفل اعمل move بمقدار معين واحسب h(n) بفل على هذا المنوال في حالة كانت قيمة h(n) بتزيد وبتوقف لما قيمة h(n) بتصير تنقص وبأخذ آخر حالة قبل ماقيمة h(n) تنقص.

* مشكلتو انو ممكن اروح على local Maxima و بالتالي ما رح صلت لأعلى قيمة.

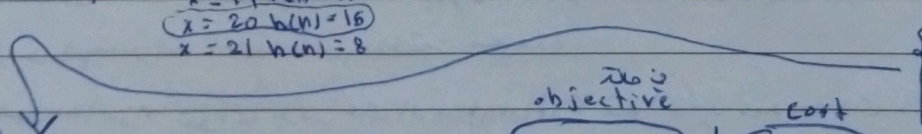

Problem: Stuck in local Maxima / Minima
(قيمة objective) (cost)

- Hill algo. هو complete و optimal لكن مش شرط

* Initial Parameters :-

- initial-Point (random).
- Move-Value. مقدار القفزات/الزيادة [كل ما كانت اقل متكون ابطأ لكن أفضل للوصول للحل وكلما كانت اكبر قد يتم القفز/التعدي عن يتم]
- Max-iteration.
- Lower-bound. أقل قيمة لرقم الاحتمال (اقل بيتة لـ X) مثلاً من 1
- UPPer-bound. أعلى قيمة لرقم الاحتمال (اعلى قيمة لـ X) الى 1000

* لو وضعت بيتها 10 مثلاً فإنو نفي لو سويت على 10 يتم وكانت قيمة الـ 10 قيم ثابتة على رقم معين مثلاً 7 فانو انهي البرنامج.

* لانها البرنامج ← اذا كانت البتم في حالة تحسن تحسن... ثم حالة سوء.
← اذا صار في سوء بالبتم (تبت).

Exploration ⇒ - عبارة عن استكشاف عام (لجميع الـ Search Space) بدون التركيز على نقطة (تطلع على الصورة الكلية).

VS

Exploitation ⇒ - استثمار لبتي بمنطقة محددة (يابتطلع على الصورة الكلية)
- بمعنى اضل بمنطقة محددة بدون النظر للمنطقة بشكل عام
فإنو بستنزف البقاء بمنطقة محددة.

~~Exploitation~~ هو اي بركز على الـ Exploration ثم التركيز بعدها على الـ ~~Exploitation~~ x ~~algorithm~~
(التركيز على الصورة العامة ثم التركيز على منطقة محددة).

* Exploration is high in the beginning and exploitation after that.

تحسينات

* There are many variants (enhancements) on the Hill-Climbing algorithm.
one of them is random-restart Hill-Climbing.

⇑

فكرتو انو اخد اكثر من initial value واعمل لكل واحد move لحتى اوصل لأفضل حل وعلما اخد اكثر من initial value راح يطلع معي افضل حل لكن الوقت (اكثر) من Hill-Climbing

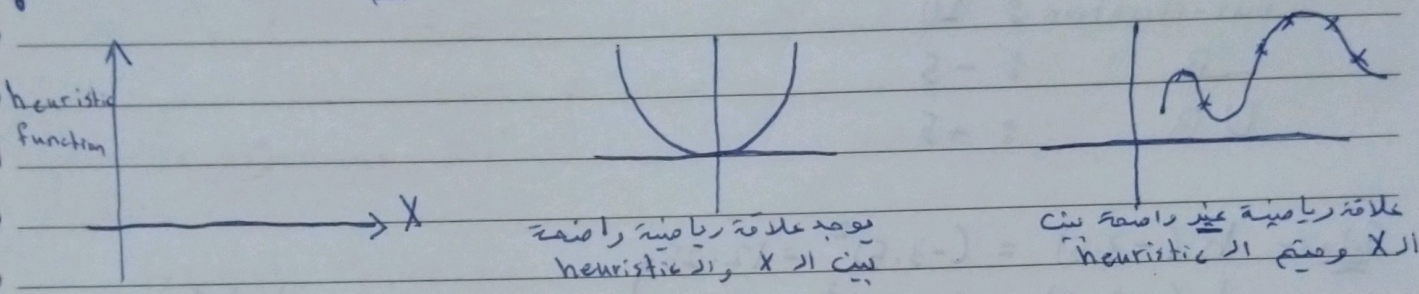

Ex: Given the following initial-state of 4-Queens Problem.

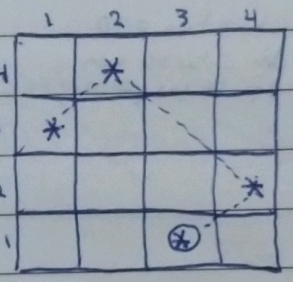

[attacking-queen (cost بحاول أقللوا)]

$h_{initial} = 2 + 1 + 1 = \underline{4}$

4 تقاطعات

Apply the Hill-Climbing algorithms.

Soln:- next-state

⊙ move the queen in col#3 to row#4

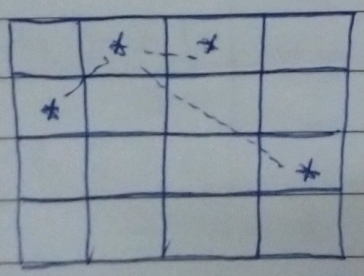

$h_{first\text{-}step} = 1 + 1 + 1 = \boxed{3}$

(الرقم نقص صار تحسّن لانه cost)

⊙ move the queen in col#1 to row#1

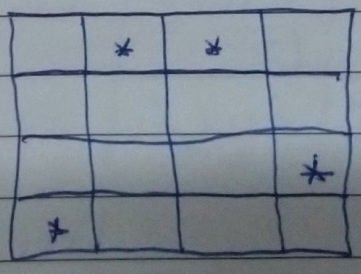

$h_{2^{nd}\text{-}step} = 1 + 1 = \boxed{2}$ ✓

افضل حل لانه اقل رقم (2).

⊙ move the queen in col#3 to row#3

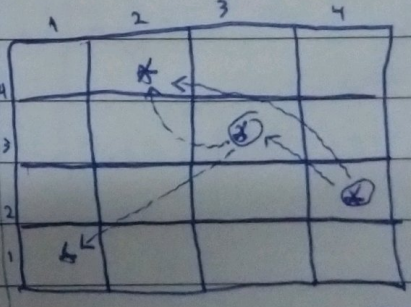

$h_{3^{rd}\text{-}step} = 2 + 2 = \boxed{4}$

الرقم كبير (صار اسوء لانه cost)

منعمل stop

Ex: suppose that $h(n) = X^2$
represent a huristic cost function.
Apply the Hill-Climbing algorithm given that:-

initial-Point : $X = -3.5$
move-value : $+1$
max-iteration : 10
LB : -5
UB : $+5$

Solu:- $h(-3.5) = (-3.5)^2 = 12.25$
$h(-2.5) = (-2.5)^2 = 6.25$ ← start
$h(-1.5) = (-1.5)^2 = 2.25$
$h(-0.5) = (-0.5)^2 = 0.25$
$h(0.5) = (0.5)^2 = 0.25$
$h(1.5) = (1.5)^2 = 2.25$ stop

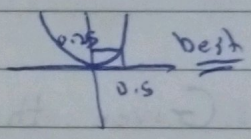

max-iteration = 10
عدد التكرارات التي تم فيها البحث عن الحل

Solution:-
The best value occurs
when $X = 0.5$
$h = 0.25$

* لو كانت initial-Point = -3 كان وصلت لـ 0 الي هو الحل الـ optimal.

8. Genetic Algorithms: P.g 126

اتشرحت عام 1960 Holland (اسم العالم)

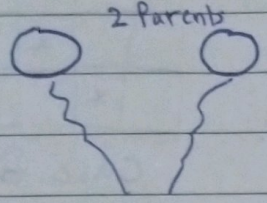

- عملية الوراثة قد تقودني لنتائج افضل او لنتائج اسوء فنأخذ الافضل ونترك الاسوء.
- Mutation (طفرة) ← قد تقودني لنتائج جذابة أو مزعجة.
- cross over

Genetic algorithm steps:-

loop

Generate Population

Find the fitness

Calculate the Probability

Crossover

Mutation

Repeat until reach the stop condition

Ex:

بشيكمانة عشوائيًا

initial Population	Fitness	Probability	Selection (randomly)	crossover	Mutation (randomly)
2 3 1 1 (العالة 1)	3	$\frac{3}{11} = 27\%$	4 2 | 3 1 (cross Point) =	4 2 1 1	4 2 (3) 1
4 2 3 1 (العالة 2)	4	$\frac{4}{11} = 36\%$	2 3 | 1 1 =	2 3 3 1	2 (2) 3 1
3 2 3 4 (العالة 3)	1	$\frac{1}{11} = 9\%$	2 3 | 1 1 =	2 3 2 1	2 3 2 1
3 1 2 1 (العالة 4)	3	$\frac{3}{11} = 27\%$	3 1 | 2 1 =	3 1 1 1	3 1 1 (4)
	Sum 11				

← First Loop

Ex :- توضيح الـ

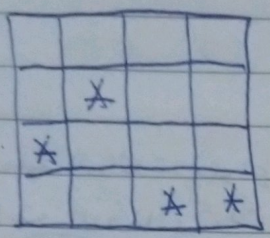

Case ①

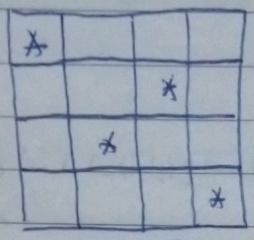

Case ②

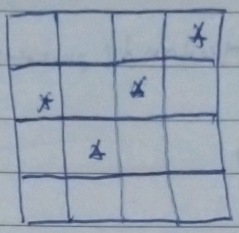

case ③

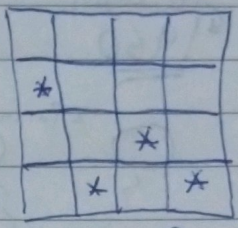

case ④

fitness [h] = 1 + 2 + 0 = 3 ← non-attacking queens

h = 2 + 1 + 1 = 4

h = 1 + 0 + 0 = 1

h = 1 + 1 + 1 = 3

{# of non-attacking queens (objective)}

4-queens = 6 ← 4-queens لـ J عدد (non-attacking)

Crossover Point : 4 2 3 | 2 ⟹ 4 2 3 4

2 3 1 | 4 ⟹ 2 3 1 2

Stop Condition :-)

1. in 4-queens (if $h = \underset{max}{6}$ for example for 4-queens)

2. Max-iteration (Stop وقف البحث وطلعت الحل بعدل) اذا خلصت امشي ع loop

* Brute-force انواعه على جميع الاحتمالات الممكنة

↓

all Combinations

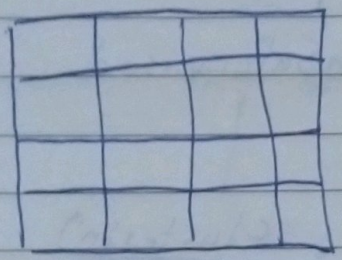

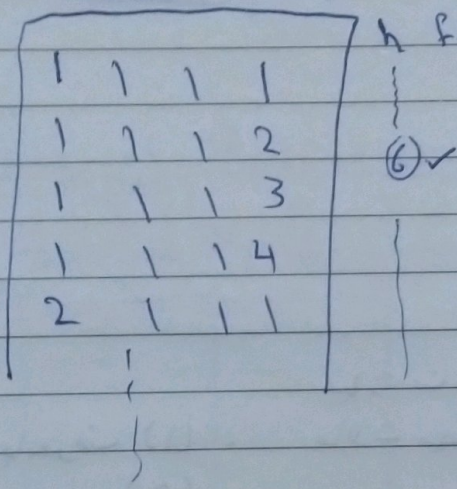

9. Function APProximation (Prediction Modeling) :-

input # of shops (x)	output Profit (y)
1	1006
2	4000
3	9000
4	16000

$Y = X^2 * 1000$

* اذا لاحظت علاقة رياضية بين الـ input والـ output ووجدت علاقة رياضية فانو بيت Model (اشتغلت Function / Model)

* Model عبارة عن ← $f(x) = X^3 - X - 1$

* في الحياة العملية الاقوام ما راح تطلع زي ما بديه (بعض شي) ، ايضا راح يكون ايجاد العلاقة بين الـ input والـ output سهل.

* فائدة اشتقاق العلاقة الرياضية في الـ Prediction (تنبؤ).

* من خلال العلاقة الرياضية المشتقة ($Y = X^2 * 1000$) قدرت أتنبأ انو لو واحد بتبع 6 shops راح يكون الـ Profit الو بيساوي 36000 ($X = 6^2 * 1000 = 36000$).

10. Learning

* عبارة عن بيانات سابقة بتدخل على الماسوب وبتطلع علاقة بين الـ input والـ output فبتصير تقدر تعمل Prediction تتنبؤ.

Learning

Supervised — UnSupervised

Supervised: Classification — Regression

Classification ⇓

بيانات مجموعة input والـ output عبارة عن مجموعة حالات محددة (مثلاً 0/1).

UnSupervised: Clustering

Examples of classifications-

①

age	gender	smoker	O/P (output)
--	--	--	1
--	--	--	0
--	--	--	1
--	--	--	1
:	:	:	:

O/P عبارة عن مجموعة حالات محددة

- اصيب بالمرض (1).
- لم يصب (0).

② img1 → human
img2 → cat
img3 → cat
img4 → dog
img5 → human
:

output الـ ⇓ مجموعة حالات محددة

* classification & output مجموعة حالات محددة.

Classification

حسب الـ data

- **Binary** ⇓ — الـ output قيمتين احتمالات
- **Multi-class** ⇓ — الـ output اكثر من احتمالات

Classification ⇒ discrete-value (قيم منفصلة)

Examples of Regression :-

x	y	z	a	h
Area	# of room	city	....	Price
				23560
				66412 →

الـ output ليست قيم محددة وانما ارقام فتعتبر Regression

$Price = a*2 + a2*X + X^2 + \dots$

Regression ⇒ continous range of value (قيم متصلة)

* Clustering :- (data الـ مش مصنفة) output مش

* Supervised Learning → في data مدربة ومع كل حالة في output

* UnSupervised Learning → الـ data غير مصنفة

Examples for clustering :- انا بصنف الـ data

① | 21 | 2 | 24 | 3 |

Sol1:

gr1	gr2
2	21
3	24

* التصنيف الاول حسب انو الارقام الاكبر قيمة تتصنف والاقل قيمة مع بعض.

Sol2:

gr1	gr2
2	3
24	21
even	odd

② 3 Folders في clustering الحالة اعطيك صور بدي folder يوجد منه مجموعة صور بدي 3 Folders وبعتنيها ك

* Measuring Accuracy in supervised Learning algorithms :- (قياس دقة الـ supervised algo.)

II Classification :-

Patients (1000) عدد المرضى | O/P

70% Training data — لغايات التدريب/التعلم

30% Testing data — لغايات الفحص

لما بدي القيمة لو توافقت مع الـ algo. منحسبها صحت # of correctly identified cases

واذا بدي توافقت بسيطرة

* قسمت الـ data في الـ classification الي مزبوط (70% و 30%) و بعد ما بعمل علامة رياضية (بطلع Model) و بعدها بعمل test من خلال الـ Model الـ 30% وبشوف اذا الـ output الي طلع متوافق مع الـ algo. ؟؟

$y_1 = ---$ $y_2 = ---$

$$\text{Accuracy}_{\text{classification}} = \frac{\text{\# of correctly identified cases}}{\text{\# of total case}}$$

كل ما زاد بكون افضل (لو وصل 100% بكون افضل حل)

$Acc1 = \frac{273}{300}$ ✓ $Acc2 = \frac{261}{300}$

معيار الدقة Accuracy اعلى

Ex:

X1	X2	X3	O/P	algo.	
					training
			1 ⟷ 0	X	testing
			0 ⟷ 0	✓	
			1 ⟷ 1	✓	

$$\text{Accuracy} = \frac{2}{3} = 0.66\%$$

عدد الحالات اللي توافقت بين الـ O/P والـ algo.

[2] Regression :-

X_1	X_2	X_3	X_4	Price
				40000

37786

* كل ما قل الرقم يكون افضل
(الوصول الى 0 يكون الافضل)

$$\text{Accuracy}_{\text{regression}} = \sqrt{\frac{\sum_{i=1}^{n} (\text{Real} - \text{Prediction})^2}{n}}$$

(القيمة الحقيقية — القيمة المتوقعة)

RMSE : Root-Mean-squared error

(الجذر التربيعي لمتوسط الخطأ)

Ex :

X_1 -----	Price	Algo. (Prediction)
	50	49
	37	40 134
	15	13

$$\text{Accuracy} = \sqrt{\frac{(50-49)^2 + (37-40)^2 + (15-13)^2}{3}}$$

$$= \sqrt{\frac{1^2 + (-3)^2 + 2^2}{3}}$$

$$= \sqrt{\frac{1+9+4}{3}} = \sqrt{\frac{14}{3}}$$

① $\sum_{i=1}^{n} (r-p)^2$ Correlates with $\sqrt{\frac{\sum_{i=1}^{n} (r-p)^2}{n}}$

② 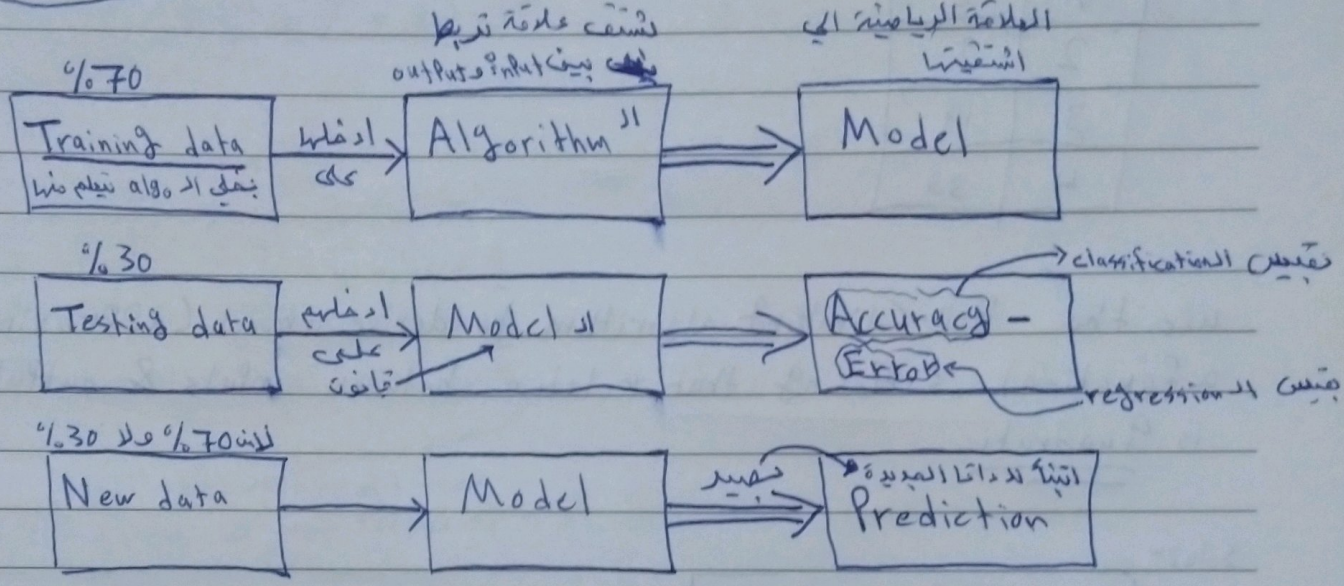

③ Semi-supervised Learning :-

مثال عليها :- عندي 1000 صورة ، folder 50 منهم مصنفا (Supervised) و 950 منهم مش مصنفا (un-supervised) ، لما عنده الحالة بهذا منهم مصنف ومنهم غير مصنف فنسمي Semi-Supervised .

④ General formula of Polynomial :-

Linear (degree = 1) $f(x) = aX + b$

Quadratic (degree = 2) $f(x) = aX^2 + bX + c$

⋮

⊙ Given the following table:-

x	y
2	9
3	19
4	33

use the Hill-Climbing algorithm to derive a model (approximate a function) supposing that relation between inputs & outputs is quadratic.

Solu:-

$f_{(x)} = a_0 x^2 + b_0 x + c_0$ quadratic

initial-values:-

$a_0 = 1 \quad b_0 = 2 \quad c_0 = 3$

$m_a = 1 \quad m_b = 1 \quad m_c = -1$

m & move

$\Longrightarrow f_0(x) = x^2 - 2x + 3$

II

x	y_{real}	$f_0(x)$ prediction
2	9	$1*4 + (-2)*2 + 3 = 3$
3	19	$1*9 + (-2)*3 + 3 = 6$
4	33	$1*16 + (-2)*4 + 3 = 11$

next → $m_a = 1 \quad m_b = 1 \quad m_c = -1$, i stay move last

$a_1 = 2 \quad b_1 = -1 \quad c_1 = 2$

$$f_1(x) = 2x^2 - x + 2$$ ✓ Hill-Climbing على أفضل حل

[2]

X	y	$f_1(x)$ Prediction
2	9	$8 - 2 + 2 = 8$
3	19	$18 - 3 + 2 = 17$
4	33	$32 - 4 + 2 = 30$

صرت اقرب للحد بشكل افضل
(real تقرب لـ Prediction)

$$RMSE_0 = \sqrt{\frac{(9-3)^2 + 13^2 + 22^2}{3}} \cong 16.\ldots$$

$$RMSE_1 = \sqrt{\frac{1^2 + 2^2 + 3^2}{3}} \cong 2.\ldots$$

Since $RMSE_1 < RMSE_0$ (improvement), then the Hill-climbing will continue.

$a_2 = 3 \quad b_2 = 0 \quad c_2 = 1$

$$f_2(x) = 3x^2 + 1$$

[3]

X	y	$f_2(x)$
2	9	13
3	19	28
4	33	49

$$RMSE_2 = \sqrt{\frac{4^2 + 11^2 + 16^2}{3}}$$

Since $RMSE_2 > RMSE_1$, then the Hill-Climbing will stop.

So, the best solution of Hill-Climbing is: $f_1(x) = 2x^2 + x + 2$.

* في حال طلب منك اجد Prediction عند $x = 6$ مثلاً 6 متغير ما باستقبل حل $f_1(x)$ استقبل حل في المثال السابق).

$$\Rightarrow f_1(x) = 2 * 6^2 + 6 + 2$$
$$= 2 * 36 + 6 + 2$$
$$= 72 + 6 + 2$$
$$= \boxed{80} \text{ Prediction}$$

* Solve using GA (Genetic Algorithm) (حل المثال السابق باستخدام):-

	a	b	c	RMSE fitness	Probability objective	Probability cost	selection	crossover	Mutation
1	1	3	-2	—	$\frac{3}{11}$	$1-\frac{3}{11}$	1 3 -2	1 3 1	1 2 1
2	2	5	4	—	$\frac{4}{11}$	$1-\frac{4}{11}$	3 1 1	3 1 -2	7 1 -2
3	3	1	1	—	$\frac{3}{11}$	$1-\frac{3}{11}$	6 2 5	6 2 1	6 2 1
4	6	2	5	—	$\frac{1}{11}$	$1-\frac{1}{11}$	3 1 1	3 1 5	3 -4 5
				Sum: 11					loop 1

Probability اجد cost randomly

* Hill-Climbing يركز على الـ Exploitation (يفضل بنفس المنطقة).

* Genetic يركز على الـ Exploration.

11. Particle Swarm Optimization (PSO):-

bird

✓ 1995

سِرب من الطيور ولنفترض ان عددها هو 25 طائر ولكل طائر يوجد PBest وبالتالي يوجد 25 PBest

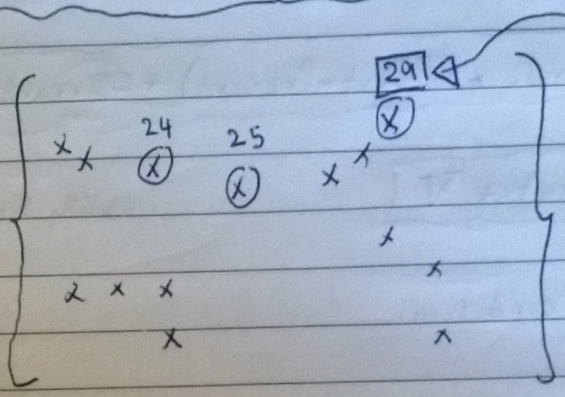

* فكرة الـ PSO انو كل طائر بصير يدور على المنطقة اي فيها الركل (more Promising).

- PBest (Particle Best).
- gBest (global Best).
- Present

* افضل مكان لكل طائر اي بلاقي فيها الركل.
* عينة وحدة وهي افضل قيمة.

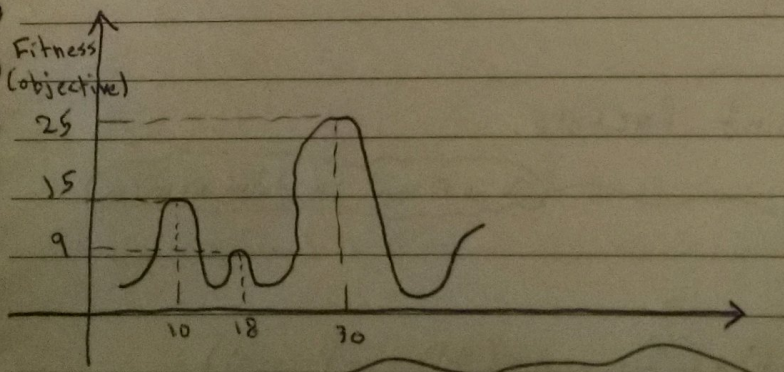

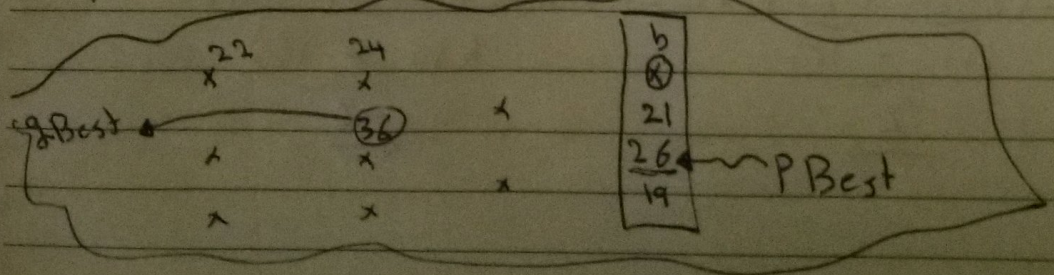

PSO Algorithm Steps:-

Particles

1. Generate initial-number-of-Population (number of birds).
2. Calculate fitness foreach Particle.
3. Generate gBest, PBest (foreach Particle).
4. $V = V + C1 * rand. * (PBest - Present) + C2 * rand. * (gBest - Present)$

   $Present = Present + V$

   بعوض بالقانون X-axis
5. Loop until stop condition.

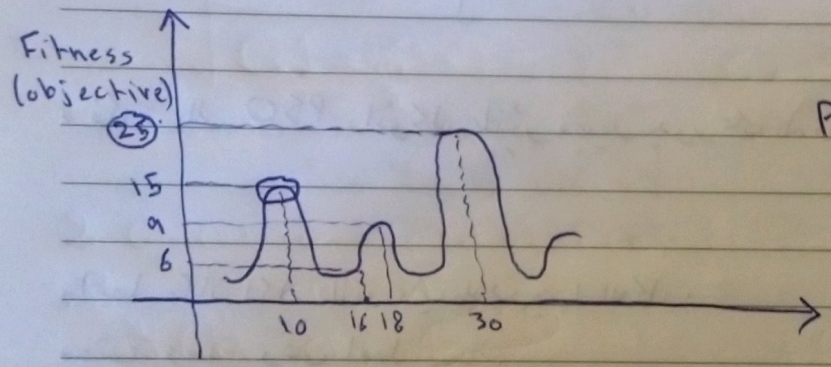

PBest = 9 when X = 18

Present = 16

fitness = 6

* rand ← بساعدني بال ← تنوع diversity

① C1 and C2 are learning factors.

② rand (0 ~ 1). ← 1 , 0 بين random number

$$V = V + \underset{1}{C1} * rand * (PBest - Present) * \underset{3}{C2} * rand * (gBest - Present)$$

$$(18 - 16) \quad (10 - 16)$$

$$2 \rightarrow \qquad -6 \leftarrow$$

* اذا كنت بدي التأثير الأكبر على gBest منحط c2 فيصير أكبر، اما اذا بدي التأثير الأكبر على pBest منحط c1 اكبر.

* ممكن اذا ضليت اروح لـ gbest اوقع بـ Stuck in local Maxima/Minima.

* Some of bio-inspired algorithms:-

- Ant Colony Optimization. خوارزمية النمل algo.
- Artificial Bee Colny (ABC). خوارزمية النحل
- ElePhant Herd algorithm. قطيع الفيلة
- FireFly algorithm. اليرقة/ذبابة
- Grey wolf Optimization الذئب

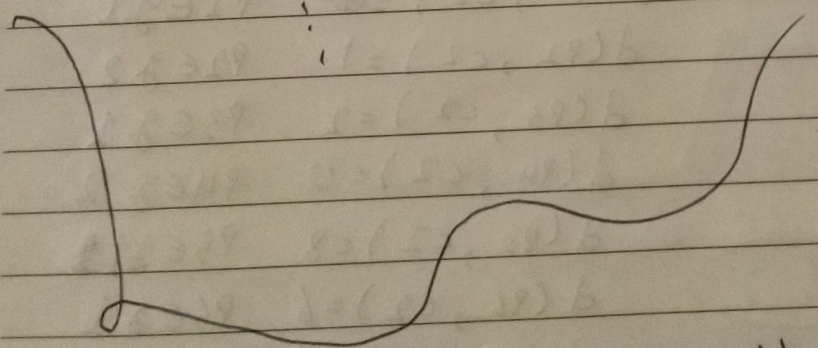

فكرتهم كلهم إنو يدرسوا الممالك الحيوانية ويترجموا اللي بصير بالممالك على شكل معادلات رياضية.

12. K-Means for Clustering :-

Ex: Given the following list of numbers :-

مجموعة نقاط (Points)	P1	P2	P3	P4	P5	P6	P7
	2	8	7	9	1	3	10

Apply K-means algorithm to Produce (two) clusters.

c1 c2

Solu :-

1. initialize the centroid for each cluster randomly. (نعرفها randomly) نعطيها بالوسط

C1 = 6 (centroid المجموعة الاولى)

C2 = 9 (centroid الي بالمجموعة الثانية)

2. Calculate the distance foreach Point in the input list.

c1 عن P1 بعد	c2 عن P1 بعد	
d(P1, c1) = 4	d(P1, c2) = 7	P1 ∈ g1
d(P2, c1) = 2	d(P2, c2) = 1	P2 ∈ g2
d(P3, c1) = 1	d(P3, c2) = 2	P3 ∈ g1
d(P4, c1) = 3	d(P4, c2) = 0	P4 ∈ g2
d(P5, c1) = 5	d(P5, c2) = 8	P5 ∈ g1
d(P6, c1) = 3	d(P6, c2) = 6	P6 ∈ g1
d(P7, c1) = 4	d(P7, c2) = 1	P7 ∈ g2

* K-means مش مهمة انو يحدد الـ clusters ، انا بحكيله قسمهم مثلاً 2 cluster فبقسمهم.

* يوجد algorithm بتحكيلك انسب عدد من الـ cluster للتقسيم.

تكملة الحل

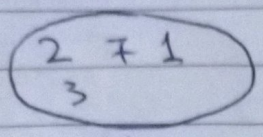

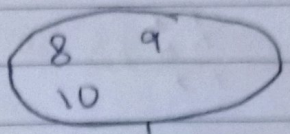

g1

g2

وسط الحسابي

$C1 = \frac{1+2+3+7}{4}$

$C2 = \frac{8+9+10}{3}$

$C1 = 3.33$

$C2 = 9$

*after new centroid c1 = 3.33 c2 = 9 ؛-

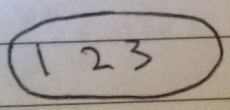

g1

$C1 = \frac{1+2+3}{3}$

$C1 = 2$

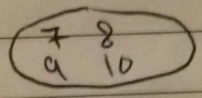

g2

$C2 = \frac{7+8+9+10}{4}$

$C2 = 8.5$

*after another new centroid c1 = 2 c2 = 8.5 ؛-

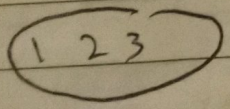

g1

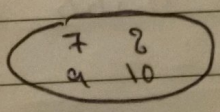

g2

* بسبب ان g1 و g2 ضلو على نفس التقسيم اللي صار بالخطوة السابقة وبالتالي الـ stop وصل لأفضل حل ممكن.

Ex:

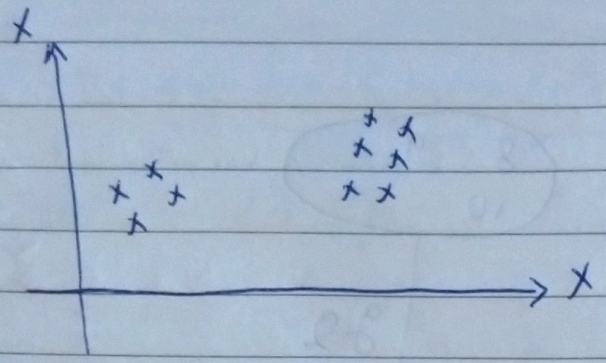

X	Y
(2, 5)	(6, 1)
(4, 9)	(5, 3)
(3, 8)	(6, 3)

} 2 clusters

Soln. :- $C1 = (3, 6)$

$C2 = (8, 4)$

$$d = \sqrt{(X2 - X1)^2 + (Y2 - Y1)^2}$$ ← المسافة بين نقطتين

(3,5)
(2,8) (1,4)

2r1

وسط حسابي

$$\bar{X} = \frac{3 + 2 + 1}{3} = 2$$

$$\bar{Y} = \frac{5 + 8 + 4}{3} = 5.66$$

new centroid (2, 5.66)

13. Neural Networks :- الشبكات العصبية

⊙ weight الوزن / التأثير

$$avg = \frac{4*(3) + 2*(3)}{6} = \frac{12+6}{6} = \frac{18}{6} = 3$$

A, C, weight نفس الـ

$$avg = \frac{4*(3) + 2*(1)}{4} = \frac{14}{4} = 3.5$$

lab

weight نفس الـ

Ex: X1 : Smoker. لأكثر من يتعرض بدون تدفئة

X2 : spend more than 6 hours without heating daily.

X3 : does not eat an apple once a week.

X1	X2	X3	o/p (cold/flu) y	اصيب بالبرد ام لا
1	0	1	1	
0	1	1	0	
1	1	1	1	
1	0	1	0	
0	1	1	0	
1	0	0	1	

الأكثر تأثيرا

$Y = (w1) * X1 + (w2) * X2 + (w3) * X3$.

weight وزن هو قيمة بنعطيها

w1 = 0.8 ← weight الأكثر تأثيرا باتخاذ القرار بكون الوزن

w2 = 0.2

w3 = 0.1

* الهدف من الـ neural networks مشان اضبط افضل قيم لـ weight

$$X1 * W1 + X2 * W2 + X3 * W3$$

$$\sum_{i=1}^{n} X_i * W_i$$

1 { $W1 = 0.8$, $W2 = 0.2$, $W3 = 0.1$ } weight افترضنا

بعوضها

(threshold) (θ تيتا)

$\sum X_i * W_i > 1.5$ (random) $\Rightarrow$ O/P : 1

$\sum X_i * W_i <= 1.5$ (θ) $\Rightarrow$ O/P : 0

2 { $W1 = 0.7$, $W2 = 0.5$, $W3 = 0.4$ } weight جديدة

بعوضها

اذا أعطتني قيمة افضل بشوف كمان احتمالات فرضًا (1000) احتمال وباخد افضل حل من ضمت الـ (1000) احتمال.

$$X1 * W1 + X2 * W2 + X3 * W3$$

معادلة ثابتة

* الـ neural network صعبة أوجد افضل حل لـ W1, W2, W3

P.166

* neural network هـ - عبارة عن نموذج للاستدلال على علاقة رياضية بين (input output) وهي مستوحاة من الدماغ البشري.

P.167
تطبيقات الـ neural network

* neural network use experience (الأداء السابقة).
* التعرف على hand written character.
* التعرف على الـ human speech (اللغة المنطوقة).
* اكتشاف مواقع المتفجرات (explosives) في المطارات.
* التعرف على نقاط سرقة credit card (stolen credit card).

figure 6.2 ✓

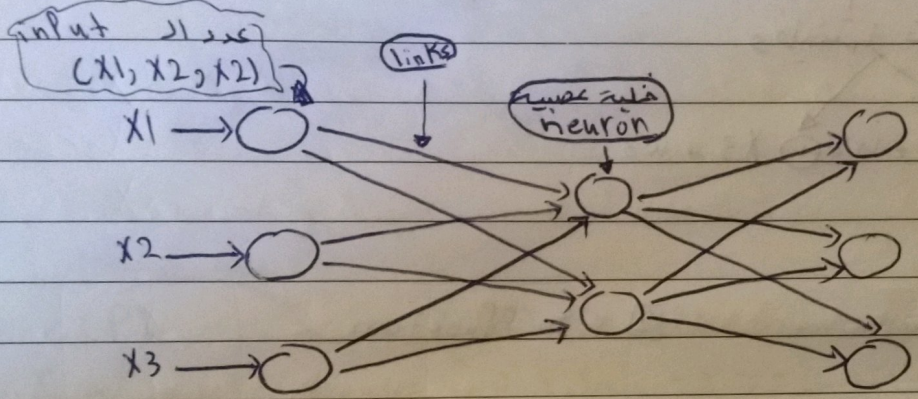

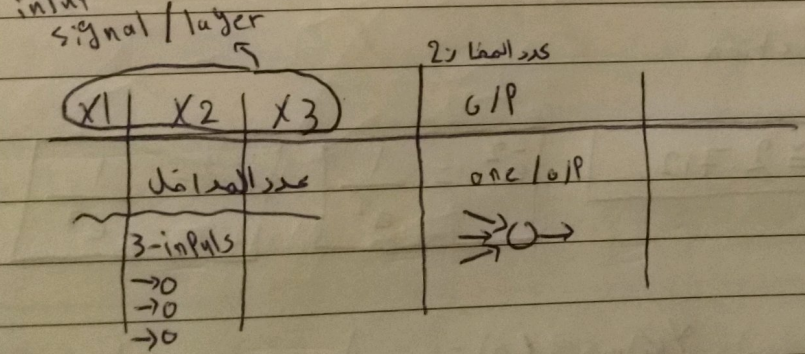

* هدف الـ neural network الوصول لأفضل معايرة الـ weight

معايرة
adjust for weight.

P.168

How does the neural network adjust to weights?

- first choose the network architecture. (يختار نوعها)
- Then decide which learning algorithm to use.
- finally training the neural network.

} build artificial neural network

نُعلّم الشبكة العصبية تعني اننا نضبط او weight.

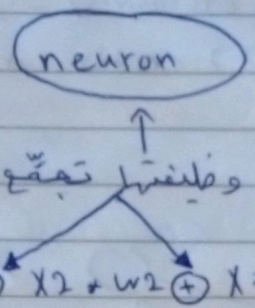

P.169

1 step functions

- $f_{step}(-5) = 0$ ($-5 < 0$)
- $f_{step}(17) = 1$ ($17 > 0$)

2 sign functions

$f_{sign}(-5) = -1$ ($-5 < 0$)

$f_{sign}(17) = 1$ ($17 > 0$)

3 sigmaid function

$$\frac{1}{1+e^{-x}}$$

$e \cong 2.712...$

$$e^{-2} = \frac{1}{e^2}$$

$$e^{-3} = \frac{1}{e^3}$$

$$\frac{1}{\infty} \cong 0$$

$$Y_{sigmoid}(0) = \frac{1}{1+e^{0}} = \frac{1}{1+\frac{1}{e^0}} = \frac{1}{1+1} = \frac{1}{2}$$

4 Linear function

$f(x) = x \Rightarrow f(2) = 2$

P.170 + P.171

The Perceptrone :-

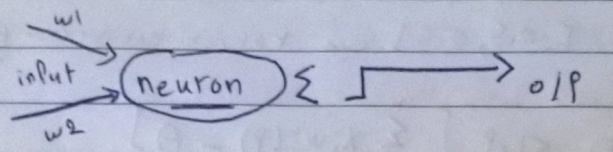

* Perceptrone : تحتوي على neuron واحدة فقط و وظيفتها الاساسية انو تعمل classification (1,0).

* $e(P) = Y_d(P) - Y(P)$

error — desired (الداتا الحقيقية) — $Y(P)$ algorithm الـ طالعها

$Y(P) = \sum x_i w_i$

* $e(P)^{+}$ طلعت موجبة $\Rightarrow Y_d(P) > Y(P)$

وتعني ان الـ algorithm تنبأ بقيم أقل من الحقيقية فحاول ازيد على $Y(P)$ [بزيد w].

* $e(P)^{+}$ موجبة $\Rightarrow$ increasing weight

* $e(P)^{-}$ سالبة $\Rightarrow$ decreasing weight

* Perceptron learning rule :

$$\underline{w}(P+1) = \underline{w}_i(P) + \boxed{\alpha \times X_i(P) \times e(P)}$$

$\underline{w}$ الجديدة — $\underline{w}$ القديمة

α ← learning rate ← مقدار الزيادة في كل مرة (بحطها من خلال التجربة)

$\underline{w}$ الجديدة اما increasing او decreasing

decreasing / increasing بتحدد لي اذا Δ صح

P.172 :-

Step1 : Initialisation : [-0.5, 0.5] بين random number ← θ و w لـ ba

Step2 : Activation : $Y(P) = step\left[\sum_{i=1}^{n} x_i w_i(P) - \theta\right]$

Step3 : weight training : $w_i(P+1) = w_i(P) + \alpha \times x_i(P) \times e(P)$

Step4 : Iteration : بعمل loop على الـ steps وكل مرة الـ weight بتتعدل لحد ما توصل لأفضل w.

* Perceptron using linearly separable Patterns. 2 بتودي لنتائج كويسة.

* Perceptron مش بتقدر على non-linearly separable function. يا 2 بتودي لنتائج كويسة

P.175

* Multilayer neural networks :- بستعملها لما الحالة تكون non-linearly seprable function

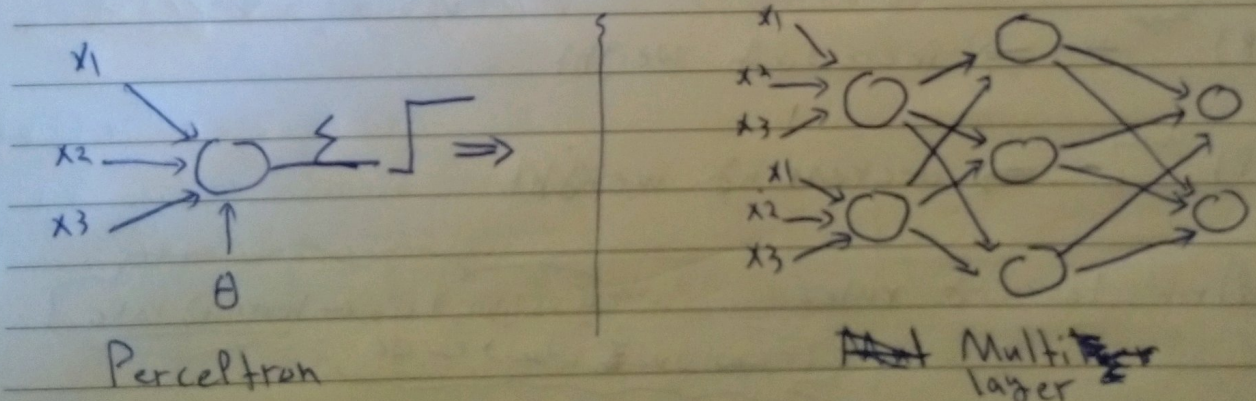

* سبب استخدام الـ Multilayer ليس الـ Perceptron : 1. non-linearly separable function 2. Neurons in the hidden layer, detect the features
(عدد الـ neurons في الـ hidden layer ← بحدد عدد الـ features)

* Multilayer learning using : back Propagation learning algorithm.
(بحدد الـ weight بطريقة عكسية)

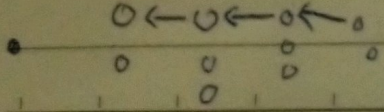

Anaconda :- Goal → Management for library of Machine learning.

SPYder → IDE — Python code يكتب فيه — 2.7 / 3.6

Python Part 1 :-

*Common Libraries :-

1 NumPy : [Matrices (n-array)] ← numeric computation / Math مجموعة اوامر عن

Ex: $\begin{bmatrix} 2 & 7 & 9 \\ 8 & 5 & 4 \\ 9 & 1 & 2 \end{bmatrix}$ $\begin{bmatrix} 2 & 1 & 1 \\ 0 & 7 & 8 \\ 9 & 1 & 5 \end{bmatrix}$

2 SciPy : linear algebra, integration (تكامل), statistics, optimization.
الاسم لها
NumPy هو

3 Pandas : manipulation / aggregation / visualization.
تعمل analysis للداتا وبحولها على شكل رسوم بيانية ..

4 MatPlotLib (Visualization) لعرض الرسومات البيانية

5 Seaborn : (advanced Visualization) لعرض رسومات احترافية.

6 SciKit-Learn : موجودة جواها الAI algorithmat الي احنا خلاص

7 Theano, TensorFlow, Keras : for Deep Learning
neural network وبعد الـ hidden layer فيها كثيرة.

* Deep : مستويات الـ hidden layers فيها كثيرة.

8 NLTK, Gensim : for Natural language Processing (NLP).

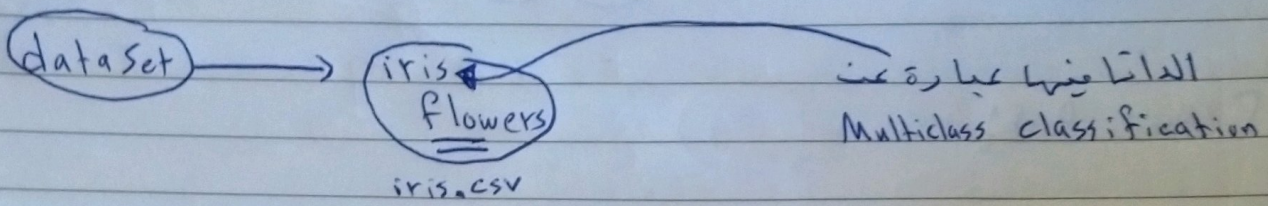

* Load The Data :

```
import Pandas
dataset = Pandas.read_csv("C:\\Users\\User1\\Downloads\\iris_dataset.csv")
```

C:\\ ✓ C:\ X C:/ ✓

* Dimensions of Dataset :

```
Print(dataset.shape)
```

output: (150, 5) — rows, columns — size

* Top rows of the Data :

```
Print(dataset.head(3))
```

يطبع اول 3 صفوف (العينة المختزنة فيها)

output

sepal length	sepal width	Petal length	Petal width	variety
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa

* Statistical summary :-

Print (dataset.describe())

	sepallength	sepal width	Petallength	Petal width
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25% ← الربيعة الأولى	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
Max	7.900000	4.400000	6.900000	2.500000

* Class Distribution :

Print(dataset.groupby('variety').size())

variety	
setosa	50
versicolor	50
virginica	50

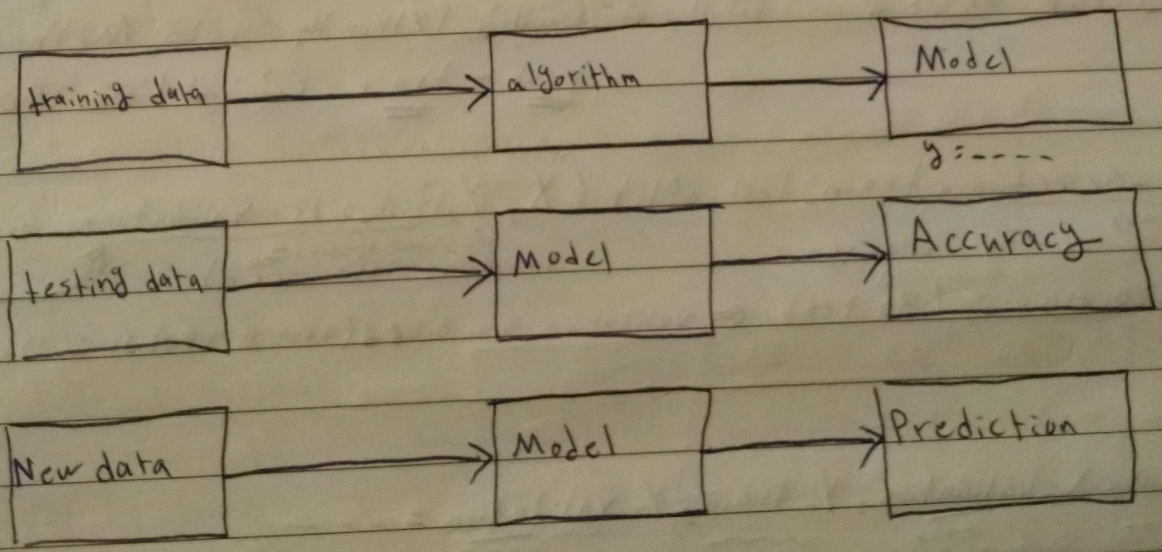

* Create a validation Dataset :-

```
from sklearn import model_selection        # library for Machine Learning
array = dataset.values                     # array[row, column]
X = array[:, 0:4]                          # not included
Y = array[:, 4]                            # just column 4
validation_size = 0.20                     # (testing data = 20%)
seed = 7
```

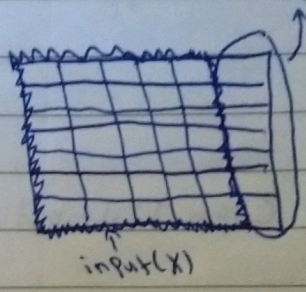

seed = 7 اولمرة
seed = 3.7 ثانيمرة
seed = 2.5 ثالث مرة
seed = 7.7 رابعمرة

* مشان احافظ على مجموعة الاعداد ال random بنفس النمط بمدد ثابت لل seed فلما حددت انو seed=7 مهما كل run رح 21 يطلع معي نفس النمط من الارقام ال random (يعطيني نفس ال series من الارقام ال random) والهدف انو لما قارنت اكثر من algo تكون المقارنة عادلة.

* train_test_split : Method جاهزة بال Python وظيفتها تقسيم الداتا test + train (مثلاً 150) لجزئين .

* model_selection . train_test_split (X, Y, test_size = validation_size, random_state = seed)
class — input output — (لتوحيد المقارنة)

0.20 * 150 = 30 test ⇐ validation_size=0.20 (test من 150) كم بدي ياه

120 training / 30 test

* X_train, X_validation, Y_train, Y_validation = ---
test test
120 row randomly — 30 row randomly — 120 row randomly — 30 row randomly

Make Predictions :-

* KNeighborsClassifier ⟶ classification لـ algo. جاهز وظيفتوا

* variable = KNeighborsClassifier() (method)
* Knn.fit(X_train, Y_train) (input, output) (fit: اوجد علاقة تربط بين)
* Predictions = Knn.Predict(X_validation) (30)
  - Predictions: variable — size = 30 row, 1 column
  - Predict: method — one parameters (بطلعلي تنبؤ ويخزنها)

* Print(accuracy_score(Y_validation, Predictions))
  - accuracy_score: method — مسألة احسب الـ accuracy
  - Y_validation: الداتا الحقيقية
  - Predictions: تنبؤ الـ algo. (30 row 1 column)

* Confusion_Matrix ⟶ Later.

Python Part 2 :-

كل كمود الوحدة نقابله

* Univariate Plots :-

```
import Pandas
dataset = Pandas.read_csv("C:\\\\ ....")
dataset.hist()
```

hist: histogram الرسم التكراري — output

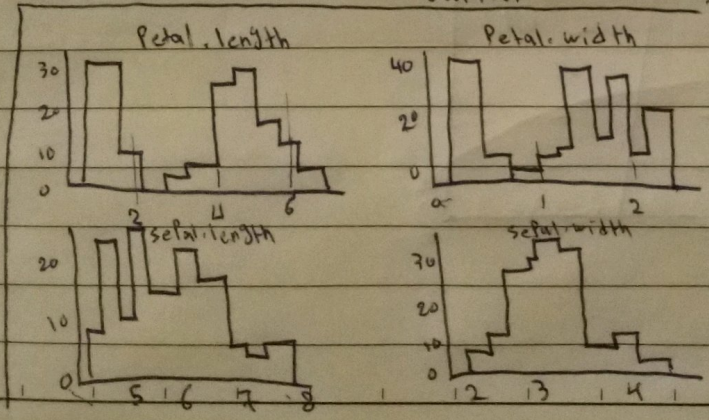

* Multivariate Plots :-

* from Pandas.Plotting import scatter_matrix
scatter_matrix(dataset)

output

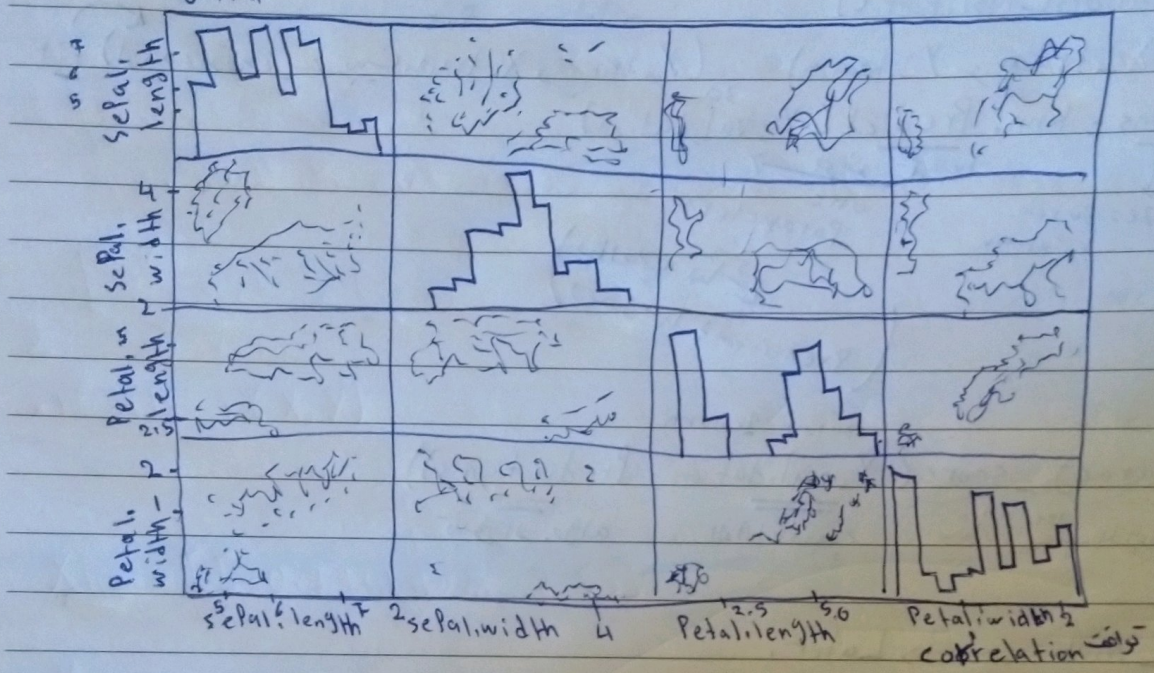

* Generating 2D classification dataset :-

* من خلالها الـ computer يعطيني متتم random (مجموعة input و output واحد) يتولد بيانات بدون ما استدعي اي ملف (بدون ما أستدعي اي dataset)

(n-features) عدد الـ features

	X1	X2	X3	X4	O/P
n-sample →	-	-	-	-	- O/P
→	-	-	-	-	-
→	-	-	-	-	-
→	-	-	-	-	-
→	-	-	-	-	-

sizeof X = 100 row
3 column

X, Y = make_blobs(n_sample = 100, centers = 2, n-features = 3, random_state = 1)

100 rows — عدد الـ rows
centers = 2 → o/p (0/1)
n-features = 3 → عدد الـ X (input)
random_state = 1 → بتديني نفس الأرقام (seed)

	rows	columns
sizeof X :	100	* 3
sizeof Y :	100	* 1

* centers = 4 ⇒ o/p → 3/2/1/0
= 10 ⇒ o/p → 9/8/7/6/5/4/3/2/1/0

* for i in rang (len(X))
عدد الـ rows
Print(----)
اطبع النتائج

for i in (5)
تتنقل من 0 الى 4

* Generating 2D regression dataset :-

X, Y = make_regression(n_samples = 4, n-features = 2, noise = 0.1)

4-row
2 input X1, X2
stder — انحراف معياري

center بالـ regression لديهم
لانه الـ o/p عبارة عن continous range of values

* اذا كانت الـ n-sample عددهم اقل من الـ centers

مثلاً n_samples = 5 - centers = 10

هيا 21 يوجد فقط اول 5 معروف

1. Class Predictions in classification :-

* LogisticRegression : يستخدم لحالات الـ classification مشان ينبأ بالـ o/p عن طريق ايجاد علاقة رياضية بين الـ inPut والـ outPut .

* LinearRegression : يستخدم لـ Regression ،

* Predict + fit : ايجاد علاقة رياضية (fit) و Predict للتنبؤ .

* [Predict ، fit ، واعمل LogisticRegression واطلب] [اعمل داتا عشوائية

model.fit(X, Y) ادرس العلاقة الرياضية بين X و Y وبحكيلي العلاقة اللي بتوصفهم .

Xnew = [[-0.7941528, 2.5]]

Ynew = model.Predict(Xnew)

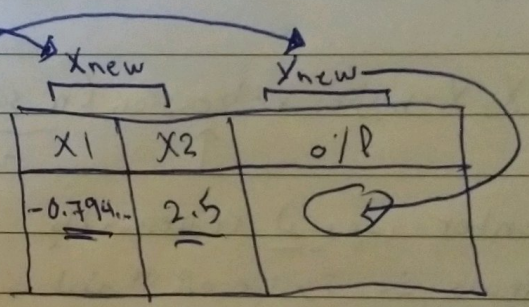

* Xnew2 → 3 row ، 2 column

* Xnew2, (-) = ...

معناها ما تفوت قيمة

* Class Prediction

X = [-0.79... ، 2.51] ، Predicted = 0

احتمالية

2. Probability Prediction) in classification:

model.Predict_Proba(Xnew)

method

بتعطيني نسبة انتماء هذا الـ output لهذه الفئة (نسبة مئوية)

X = [-0.79 -4.71], Predicted = [0.0045, 0.995]

↑ Predicted احتمالية

* لو center=3 ← Predicted بعطيني 3 احتمالات

* معظم الـ classification algo. بتنبأ بالـ Probability باستثناء بعض الـ algo.

3. Predictions with regression models:-

* LinearRegression for → Regression

* Xnew, ⊖ = ---

↑ Xnew ماينفي

Python Part 3 :-

* K-fold cross validation :

* أشهر طريقتين لتقييم دقة Model / algorithm مُبين كما :-

1. train-test-split :-

* فكرتها انو لو عندي (100 row) بأخذ مثلاً 85 لل train و 15 لل test
وبجري دراسة ومشان اطلع علاقة بين input و الoutput .
على الtraining

2. cross-validation :-

* فكرتها انو فرضنا عندي 100 row (70 row train 30 row test)
فكرتوا أنو بحكيلك الـ 30 row اللي ما أُجريت عليهم دراسة ممكن أطلع
منهم داتا أفضل ؟ فبأخذ كل الداتا .

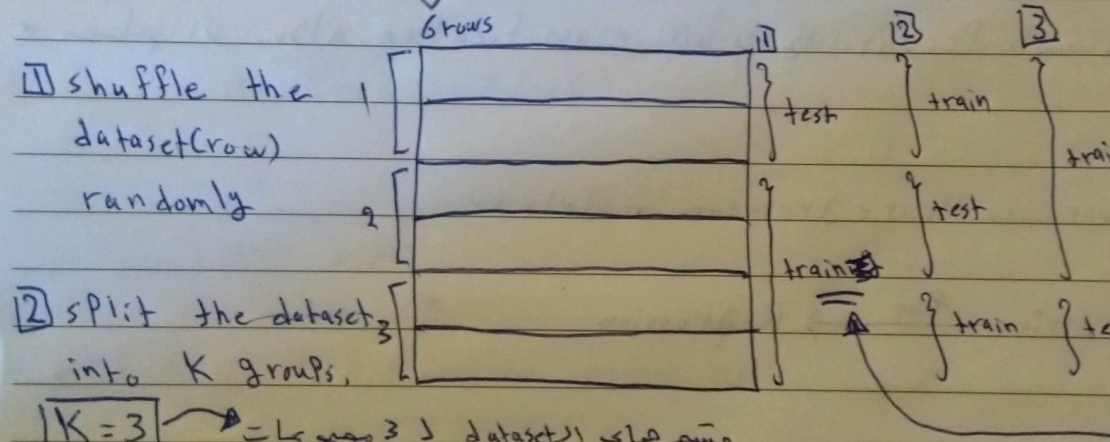

مقسم صفوف الdataset لـ 3 مجموعات

* بحط الـ algo و بشوف النتائج
وبجيب علاقة بين input و output .

* أفضل قيمة لـ K بين 5 و 10 .

* نسبة دقة الجواب في الcross-validation أعلى من train-test-split
وبالتالي رح توصلني لنتائج أفضل بدقة أعلى .